数据挖掘期中考试 A

姓名:
学号:

1. 下列哪一项最能体现“数据挖掘”的核心目标?
A. 数据存储与压缩　　**B. 从数据中发现潜在模式和规律**
C. 数据收集与录入　　D. 数据传输与备份

2. 异常值分析的典型应用场景是?
A. 商品聚类　**B. 信用卡欺诈检测**　C. 图像分类　D. 文本聚类

3. 以下哪组属性的划分存在错误?
A. 体重（比率）　B. （摄氏度）温度（区间）　C. 颜色（名义）　**D. 性别（序数）**

4. 下列哪一项属于定量属性?
A. 血型　B. 军衔　**C. 月收入**　D. 职业

5. 对于邮政编码这一属性，下列说法最合理的是?
A. 它是数值型属性，因为由数字组成　　**B. 它是名义型属性，因为数字仅代表标签**
C. 它是序数属性，因为可以排序　　D. 它是比率属性，因为可以比较倍数关系

6. 假设属性月收入的最大值是 10000 元，最小值是 2000 元。利用最大最小规范化的方法将该属性的值映射到 0 至 1 的范围内，那么属性月收入为 6000 元将被转化为多少?
A 0.25　**B 0.5**　C 0.75　D 1

7. 以下关于离散属性和连续属性的描述中，错误的是?
A. 离散属性取值可数，通常为整数　　B. 连续属性取值为实数，可取任意精度
C. 连续属性可以离散化以便分析　　**D. 二元属性是连续属性的一种特殊形式**

8.月收入的分组频数为：0-2（120），2-4（180），4-6（300），6-10（250），10-20（100）。该样本的近似中位数最接近下列哪一项?
A. 4.67 k　**B. 5.17 k**　C. 5.80 k　D. 6.00 k

9. 两变量的相关系数 r = -0.95，说明:
A. 两者无关　B. 存在强正相关　**C. 存在强负相关**　D. 完全不相关

10. 下列关于比率尺度的描述正确的是:
A. 无真实零点　B. 仅适用于名义变量　**C. 具有真实零点**　D. 仅用于离散数据

11. 方差越大，说明:
A. 数据集中趋势越强　**B. 数据离散程度越高**　C. 平均值越大　D. 异常值越少

12. 在事务型数据库中，每条交易称为:
A. 项　B. 样本　**C. 事务**　D. 属性

13. FPGrowth 算法的主要优势是:
A. 无需生成候选项集　B. 扫描数据库次数多　C. 时间复杂度高　D. 结果不准确

14. 时间约束 max-gap = 2, min-gap = 0, max-span = 4 表示?
A. 两个事件间的时间差至少为 2　　**B. 两个事件间的最大间隔为 2**
C. 整个序列跨度不能超过 2　　D. 最小间隔为 4

15. ECLAT 和 SPADE 算法使用的核心思想是：
A. 基于水平数据扫描　**B. 基于事务交集（垂直数据格式）**　C. 基于矩阵分解　D. 基于统计检验

16. 下表展示了两个顾客 A 和 B 对五种产品的购买记录（1 表示购买，0 表示未购买）：

产品	P1	P2	P3	P4	P5
顾客 A	1	0	1	1	0
顾客 B	1	1	0	1	0

根据表中数据，计算顾客 A 与顾客 B 之间的 Jaccard 相似系数（适用于非对称二元属性）：

$$sim(i,j)=\frac{q}{q+r+s}=1-d(i,j).$$

A. 0.25　B. 0.33　**C. 0.50**　D. 0.67

17. 若最小支持度 σ = 40%，下列关于项集的说法中，哪一项是错误的？
A. 如果 {牛奶，果冻} 是频繁项集，则 {牛奶} 一定也是频繁项集
B. 如果 {果冻，啤酒} 不是频繁项集，则 {啤酒} 一定不是频繁项集
C. {牛奶，果冻，面包} 的所有子集必须在生成前进行频繁性检查
D. 若 {果冻} 是频繁项集，不代表 {果冻，面包} 一定频繁

18. 关于空值不变性，以下哪一项说法最正确？
A. 当样本中空交易（即既不包含 A 也不包含 B 的事务）数量大幅增加时，Lift 值不会改变，因为它只依赖于 s(A) 和 s(B)。
B. 当空交易增多时，χ^2 与 Lift 都可能显著下降或上升，因此它们不具备空值不变性。
C. 空值不变性意味着：如果新增若干全为空的交易，所有相似度度量都会保持不变。
D. Jaccard、AllConf 和 Kulczynski 都不具有空值不变性。

19. 在序列模式挖掘中，下列关于序列和项集的描述中，错误的是？
A. 序列是由若干按时间顺序排列的元素组成的，每个元素可以包含一个或多个事件（项）
B. 序列中元素的顺序可以随意交换，但元素内部的项集顺序不可以交换
C. 序列的长度等于序列中元素的个数
D. 当一个序列包含 3 个元素和 4 个事件时，称其为 4-序列

20. 下面选项中 t 不是 s 的子序列的是？
A. s=<{2,4},{3,5,6},{8}> t=<{2},{3,6},{8}>　B. s=<{2,4},{3,5,6},{8}> t=<{2},{8}>
C. s=<{1,2},{3,4}> t=<{1},{2}>　D. s=<{2,4},{2,4}> t=<{2},{4}>

21. 若数据库中部分商品利润可能为负值，下列关于约束性质的描述中，错误的是？
A. 当所有商品利润 ≥ 0 时，约束 sum(profit) ≥ v 属于单调约束。
B. 当所有商品利润 ≥ 0 时，约束 sum(profit) ≤ v 属于反单调约束。
C. 当存在负利润商品时，约束 sum(profit) ≥ v 仍然保持单调性。
D. 当存在负利润商品时，约束 sum(profit) ≤ v 不再具有反单调性。

22. 在有约束的频繁模式挖掘中，下列说法中哪一项错误？
A. 利用单调约束可在搜索初期提前扩展满足条件的候选。
B. 利用反单调约束可在搜索树上提前剪除不满足条件的分支。
C. 可转换约束必须在全局排序下才具备单调或反单调性质。
D. 若约束与支持度阈值不相关，则无法进行任何剪枝。

23. 若规则 A→B 的提升度（Lift）大于 1，则说明？
A. A 和 B 负相关　B. A 和 B 独立
C. A 的出现增加 B 出现的可能性　D. A 的出现降低 B 出现的可能性

24. 已知数据序列 d = <{1,3} {2} {4,5} {6} {7,8}>(t=0 到 t=4)，序列模式 s = <{1} {5} {7}>，且时间约束为 max-gap = 2。下列说法错误的是？
A. 从时间约束角度，d 包含 s
B. 若将 s 视为连续子序列的判断对象，d 不包含 s
C. 若时间约束改为 max-gap = 3，d 包含 s
D. 数据序列 d 中，<{2} {4,5}> 是连续子序列

25. 已知频繁项集 F_3 = {abc, abd, acd, ace, bcd}，通过 Apriori 算法生成候选 4 项集 C_4。以下选项中，可能属于 C_4 的是？
A. abcd　B. abce　C. acde　D. bcde

二：计算题

1. 以下是五位顾客在外卖平台上的点餐记录，每位顾客在一次下单中所购买的餐品如下(minsup=2)：

订单编号	订单包含的餐品
01	{炸鸡，可乐，汉堡，沙拉}
02	{可乐，炸鸡，汉堡}
03	{汉堡，奶茶，沙拉，咖啡}
04	{炸鸡，汉堡，沙拉，可乐}
05	{可乐，汉堡}

菜单利润如下：炸鸡：20，可乐：15，汉堡：30，沙拉：25，奶茶：20

利用 FP-Growth 算法回答以下问题（共 15 分）：
1. (6 分) 根据以上数据，构建全局 FP 树并写出支持度 ≥ 2 的所有频繁项集
2. (3 分) 若设约束为平均利润 ≥ 23，列出所有满足约束的频繁项集
3. (6 分) 从满足约束的频繁项集中选出包含炸鸡和沙拉的三项集，并计算所有强规则(minconf=0.6)的 s,c,l 并简要解释其含义。

2. 给定序列数据库如下(minsip=40%)：

交易日期	顾客 ID	购买的商品	交易日期	顾客 ID	购买的商品
2025-05-10	C2	10,20	2025-05-25	C1	30
2025-05-12	C5	90	2025-05-30	C1	90
2025-05-15	C2	30	2025-05-30	C4	40,70
2025-05-20	C2	40,60,70	2025-06-01	C4	90
2025-05-25	C4	30	2025-06-01	C2	90
2025-05-25	C3	30,50,70			

时间约束：max-gap ≤ 20 天（相邻事件的日期差不超过 20 天；同一天视为同一事件）。

请用 GSP 算法回答：
(1) (4分) 写出上面每位顾客的购物序列
(2) (6分) 计算频繁 1-序列 L1 与频繁 2-序列 L2
(3) (5分) 在 L2 基础上生成候选 3-序列，指出哪些被剪枝并说明原因

3.给定下表的序列数据库(minsup=50%)

sid	Sequence
10	〈 a (a b c) (a c) d (c f) 〉
20	〈 (a d) c (c b) (a e) 〉
30	〈 (e f) (a b) (d f) c b 〉
40	〈 e g (a f) c b c 〉

1.(5 分) 写出每个频繁 1-序列的投影数据库
2.(5 分) 以前缀〈{a,c}〉进行投影，写出由〈{a,c}〉扩展得到的所有频繁 2-序列
3.(5 分) 构造〈{d}{c}〉为前缀的投影数据库，并找出所有频繁的 1-扩展并给出支持度

==========

一. 选择题答案

1.	6.	11.	16.	21.
2.	7.	12.	17.	22.
3.	8.	13.	18.	23.
4.	9.	14.	19.	24.
5.	10.	15.	20.	25.

二. 计算题答案