# 决策树作业

| 编号 | 年龄 | 有工作 | 有房子 | 信用 | 是否批准贷款（Y/N） | 预估投资金额（万元） |
|---|---|---|---|---|---|---|
| 1 | 青年 | 否 | 否 | 一般 | 否 | 15 |
| 2 | 青年 | 否 | 否 | 好 | 否 | 18 |
| 3 | 青年 | 是 | 否 | 好 | 是 | 40 |
| 4 | 青年 | 是 | 是 | 一般 | 是 | 55 |
| 5 | 中年 | 否 | 否 | 一般 | 否 | 20 |
| 6 | 中年 | 否 | 否 | 好 | 否 | 28 |
| 7 | 中年 | 是 | 否 | 好 | 是 | 60 |
| 8 | 中年 | 否 | 否 | 非常好 | 是 | 70 |
| 9 | 中年 | 否 | 是 | 非常好 | 是 | 85 |
| 10 | 老年 | 否 | 是 | 非常好 | 是 | 80 |
| 11 | 老年 | 否 | 否 | 好 | 是 | 65 |
| 12 | 老年 | 是 | 否 | 好 | 是 | 70 |
| 13 | 老年 | 是 | 是 | 非常好 | 是 | 90 |
| 14 | 老年 | 否 | 否 | 一般 | 否 | 30 |

1. ID3 算法（分类）

1. 以“是否批准贷款”为目标变量；
2. 使用信息增益（Entropy）作为划分标准；
3. 手工计算每个特征的信息增益；
4. 选择信息增益最大的特征作为根节点；
5. 画出完整的决策树结构；
6. 不进行剪枝。

2. C4.5 算法（分类 + 预剪枝）

1. 使用信息增益率（Gain Ratio）作为划分标准；
2. 使用以下预剪枝条件：
   - 当节点样本数小于 5 时停止划分；
   - 当信息增益率小于 0.05 时停止划分；

- 树深度最大值 max_depth = 3;

3. 画出最终的剪枝后决策树;
4. 对比剪枝前后树结构及分类准确率变化。

3. CART 算法（分类）

1. 使用基尼指数（Gini Index）作为划分标准;
2. 先建立完整的 CART 分类树;
3. 绘制决策树并进行对比。

4. CART 回归树

1. 以“预估投资金额（万元）”为目标变量;
2. 使用均方误差（MSE）作为划分标准;
3. 手工计算第一次划分（例如按“年龄”）的 MSE;
4. 绘制回归树;
5. 对以下测试样本预测其投资金额:

| **年龄** | **有工作** | **有房子** | **信用** | 预计投资金额 |
|---|---|---|---|---|
| 中年 | 否 | 是 | 一般 | ? |

## 第一题 ID3算法（分类）

以下为手工计算每个特征的信息增益的过程和最终的决策树结构：

$$\mathrm{Info}(D) = I(9,5) = -\frac{9}{14}\log_2\left(\frac{9}{14}\right) - \frac{5}{14}\log_2\left(\frac{5}{14}\right) = 0.940$$

$$\begin{aligned}\mathrm{Info}_{age}(D) &= \frac{4}{14}I(2,2) + \frac{5}{14}I(3,2) + \frac{5}{14}I(4,1)\\ &= \frac{4}{14}\times 1 + \frac{5}{14}\times 0.971 + \frac{5}{14}\times 0.722\\ &= 0.890\end{aligned}$$

$$\begin{aligned}\mathrm{Info}_{work}(D) &= \frac{9}{14}I(4,5) + \frac{5}{14}(5,0)\\ &= 0.637\end{aligned}$$

$$\begin{aligned}\mathrm{Info}_{house}(D) &= \frac{4}{14}I(4,0) + \frac{10}{14}(5,5)\\ &= 0.714\end{aligned}$$

$$\begin{aligned}\mathrm{Info}_{credit}(D) &= \frac{4}{14}I(4,0) + \frac{6}{14}I(4,2) + \frac{4}{14}I(1,3)\\ &= 0.625\end{aligned}$$

$$\mathrm{Gain}(age) = \mathrm{Info}(D) - \mathrm{Info}_{age}(D) = 0.05$$

$$\mathrm{Gain}(work) = \mathrm{Info}(D) - \mathrm{Info}_{work}(D) = 0.303$$

$$\mathrm{Gain}(house) = \mathrm{Info}(D) - \mathrm{Info}_{house}(D) = 0.226$$

$$\mathrm{Gain}(credit) = \mathrm{Info}(D) - \mathrm{Info}_{credit}(D) = 0.315$$

## 第二题 C4.5 算法（分类 + 预剪枝）

通过程序进行计算，由于代码篇幅过长，只贴出程序运行结果：

```
==============================
构建未剪枝树（只打印每步 GR）
==============================

========== 未剪枝：第 1 次划分（深度=1）==========
--- 信息增益率（Gain Ratio） ---
特征 年龄: GR = 0.031680
特征 有工作: GR = 0.322419
特征 有房子: GR = 0.261841
特征 信用: GR = 0.202316
选择特征：有工作（GR=0.322419）

========== 未剪枝：第 2 次划分（深度=2）==========
--- 信息增益率（Gain Ratio） ---
特征 年龄: GR = 0.157160
特征 有工作: GR = 0.000000
特征 有房子: GR = 0.418422
特征 信用: GR = 0.432173
选择特征：信用（GR=0.432173）

========== 未剪枝：第 3 次划分（深度=3）==========
纯节点 → 不再划分

========== 未剪枝：第 4 次划分（深度=3）==========
纯节点 → 不再划分

========== 未剪枝：第 5 次划分（深度=3）==========
--- 信息增益率（Gain Ratio） ---
特征 年龄: GR = 0.579380
特征 有工作: GR = 0.000000
特征 有房子: GR = 0.000000
特征 信用: GR = 0.000000
选择特征：年龄（GR=0.579380）

========== 未剪枝：第 6 次划分（深度=4）==========
纯节点 → 不再划分

========== 未剪枝：第 7 次划分（深度=4）==========
纯节点 → 不再划分

========== 未剪枝：第 8 次划分（深度=4）==========
纯节点 → 不再划分

========== 未剪枝：第 9 次划分（深度=2）==========
纯节点 → 不再划分

未剪枝树结构：
特征: 有工作
 [否]
    特征: 信用
     [一般]
        --> 标签: 否
     [非常好]
        --> 标签: 是
     [好]
        特征: 年龄
         [老年]
```

```
            --> 标签: 是
        [青年]
            --> 标签: 否
        [中年]
            --> 标签: 否
 [是]
    --> 标签: 是

未剪枝整体准确率: 1.000000

==============================
构建预剪枝树（每步打印剪枝 vs 划分准确率比较）
==============================

========== 预剪枝: 第 1 步（深度=1）==========
--- 各特征 Gain Ratio ---
特征 年龄: GR = 0.031680
特征 有工作: GR = 0.322419
特征 有房子: GR = 0.261841
特征 信用: GR = 0.202316
最佳候选特征: 有工作（GR=0.322419）

准确率对比: 不划分(剪枝为叶) = 0.642857, 划分(占位子叶) = 0.714286
差值（划分 - 不划分）= +0.071429
✓ 划分有利 → 继续划分

========== 预剪枝: 第 2 步（深度=2）==========
--- 各特征 Gain Ratio ---
特征 年龄: GR = 0.157160
特征 有工作: GR = 0.000000
特征 有房子: GR = 0.418422
特征 信用: GR = 0.432173
最佳候选特征: 信用（GR=0.432173）

准确率对比: 不划分(剪枝为叶) = 0.357143, 划分(占位子叶) = 0.642857
差值（划分 - 不划分）= +0.285714
✓ 划分有利 → 继续划分

========== 预剪枝: 第 3 步（深度=3）==========
纯节点 → 不划分（叶）

========== 预剪枝: 第 4 步（深度=3）==========
纯节点 → 不划分（叶）

========== 预剪枝: 第 5 步（深度=3）==========
--- 各特征 Gain Ratio ---
特征 年龄: GR = 0.579380
特征 有工作: GR = 0.000000
特征 有房子: GR = 0.000000
特征 信用: GR = 0.000000
最佳候选特征: 年龄（GR=0.579380）

准确率对比: 不划分(剪枝为叶) = 0.357143, 划分(占位子叶) = 0.571429
差值（划分 - 不划分）= +0.214286
样本数 < 5 → 剪枝（不划分）

========== 预剪枝: 第 6 步（深度=2）==========
纯节点 → 不划分（叶）
```

```

预剪枝树结构:
特征: 有工作
 [否]
    特征: 信用
     [一般]
        --> 标签: 否
     [非常好]
        --> 标签: 是
     [好]
        --> 标签: 否
 [是]
    --> 标签: 是

预剪枝整体准确率: 0.928571

==============================
最终准确率对比
==============================
未剪枝: 1.000000
预剪枝: 0.928571
差值（预剪枝 - 未剪枝）: -0.071429
已输出 matplotlib 图片: unpruned_tree_matplotlib.png / .pdf, pruned_tree_matplotlib.png / .pdf
已输出 Graphviz 图片: unpruned_tree_graphviz.png/.pdf, pruned_tree_graphviz.png/.pdf
```

以下为未剪枝的图片:

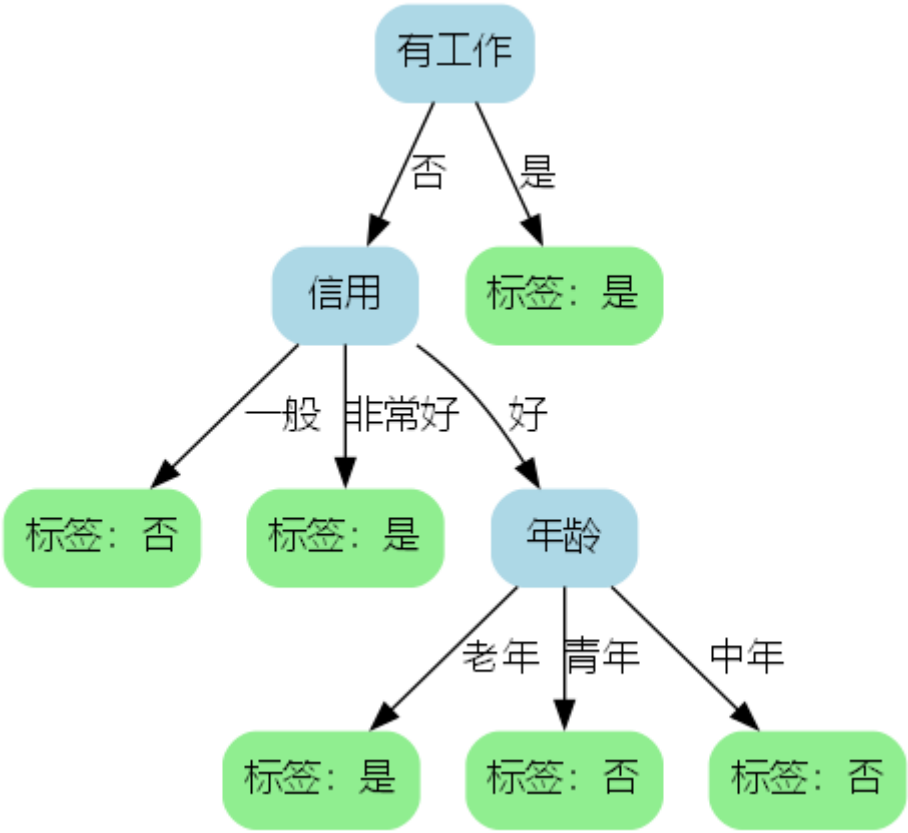


以下为预剪枝后的图片:

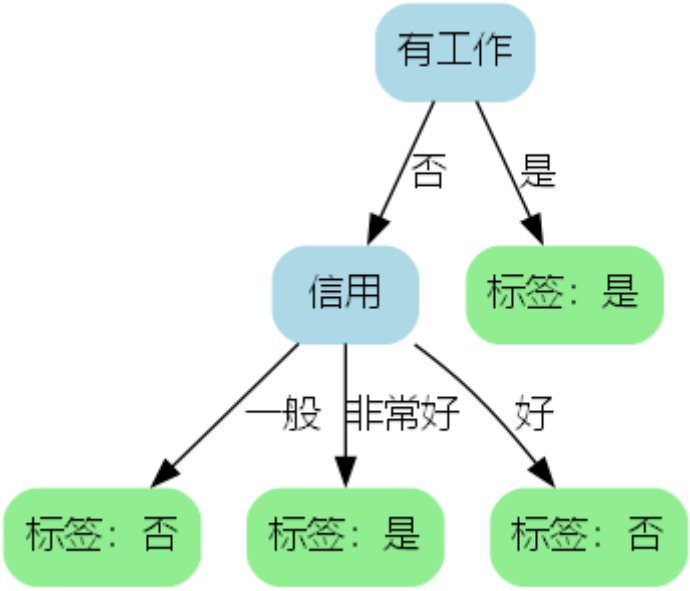


## 第三题 CART 算法（分类）

通过程序进行计算，由于代码篇幅过长，只贴出程序运行结果：

```
==============================
① 构建未剪枝 CART（每步输出 Gini 比较）
==============================

========== CART 构建：第 1 次划分（深度=1）==========
--- 各特征 Gini 指数（越小越好） ---
特征 年龄: Gini = 0.428571
特征 有工作: Gini = 0.317460
特征 有房子: Gini = 0.357143
特征 信用: Gini = 0.297619
✅ 选择最优特征：信用（Gini=0.297619）

========== CART 构建：第 2 次划分（深度=2）==========
--- 各特征 Gini 指数（越小越好） ---
特征 年龄: Gini = 0.333333
特征 有工作: Gini = 0.222222
特征 有房子: Gini = 0.444444
特征 信用: Gini = 0.444444
✅ 选择最优特征：有工作（Gini=0.222222）

========== CART 构建：第 3 次划分（深度=3）==========
纯节点 → 停止划分

========== CART 构建：第 4 次划分（深度=3）==========
--- 各特征 Gini 指数（越小越好） ---
特征 年龄: Gini = 0.000000
特征 有工作: Gini = 0.444444
特征 有房子: Gini = 0.444444
特征 信用: Gini = 0.444444
✅ 选择最优特征：年龄（Gini=0.000000）

========== CART 构建：第 5 次划分（深度=4）==========
纯节点 → 停止划分

========== CART 构建：第 6 次划分（深度=4）==========
```

```
纯节点 → 停止划分

========== CART 构建：第 7 次划分（深度=4）==========
纯节点 → 停止划分

========== CART 构建：第 8 次划分（深度=2）==========
--- 各特征 Gini 指数（越小越好） ---
特征 年龄: Gini = 0.250000
特征 有工作: Gini = 0.000000
特征 有房子: Gini = 0.000000
特征 信用: Gini = 0.375000
✅ 选择最优特征：有工作（Gini=0.000000）

========== CART 构建：第 9 次划分（深度=3）==========
纯节点 → 停止划分

========== CART 构建：第 10 次划分（深度=3）==========
纯节点 → 停止划分

========== CART 构建：第 11 次划分（深度=2）==========
纯节点 → 停止划分

-- 未剪枝树结构 --
特征：信用
  [好]
  特征：有工作
    [是]
    → 叶：是
    [否]
    特征：年龄
      [青年]
      → 叶：否
      [中年]
      → 叶：否
      [老年]
      → 叶：是
  [一般]
  特征：有工作
    [是]
    → 叶：是
    [否]
    → 叶：否
  [非常好]
  → 叶：是

==============================
② 自底向上后剪枝（逐节点输出剪枝前/后损失比较）
==============================

========== 后剪枝：第 1 次判断（深度=3，样本数=3）==========
【剪枝前后损失函数比较（基于本节点子集）】
L_subtree（保留子树）= 0 / 3 = 0.000000
L_leaf    （剪为叶）   = 1 / 3 = 0.333333
❌ 决策：不剪枝（保留子树更优）

========== 后剪枝：第 2 次判断（深度=2，样本数=6）==========
【剪枝前后损失函数比较（基于本节点子集）】
L_subtree（保留子树）= 0 / 6 = 0.000000
```

```
L_leaf    （剪为叶）   = 2 / 6 = 0.333333
❌ 决策：不剪枝（保留子树更优）

========== 后剪枝：第 3 次判断（深度=2，样本数=4）==========
【剪枝前后损失函数比较（基于本节点子集）】
L_subtree（保留子树）= 0 / 4 = 0.000000
L_leaf    （剪为叶）   = 1 / 4 = 0.250000
❌ 决策：不剪枝（保留子树更优）

========== 后剪枝：第 4 次判断（深度=1，样本数=14）==========
【剪枝前后损失函数比较（基于本节点子集）】
L_subtree（保留子树）= 0 / 14 = 0.000000
L_leaf    （剪为叶）   = 5 / 14 = 0.357143
❌ 决策：不剪枝（保留子树更优）

-- 剪枝后树结构 --
特征：信用
  [好]
  特征：有工作
    [是]
    → 叶：是
    [否]
    特征：年龄
      [青年]
      → 叶：否
      [中年]
      → 叶：否
      [老年]
      → 叶：是
  [一般]
  特征：有工作
    [是]
    → 叶：是
    [否]
    → 叶：否
  [非常好]
  → 叶：是

==============================
③ 绘图
==============================
✅ 已生成：CART_full.png
✅ 已生成：CART_pruned.png

==============================
④ 准确率对比
==============================
未剪枝：1.000000
后剪枝：1.000000
```

以下为未剪枝的图片：

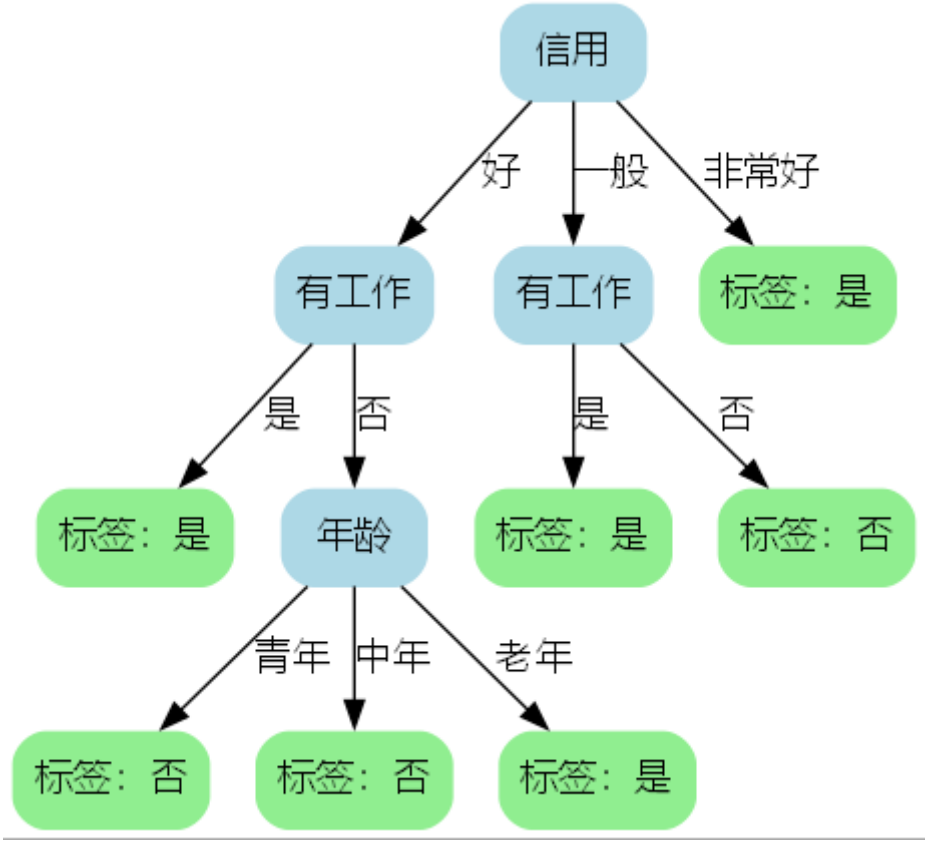


以下为剪枝后的图片：

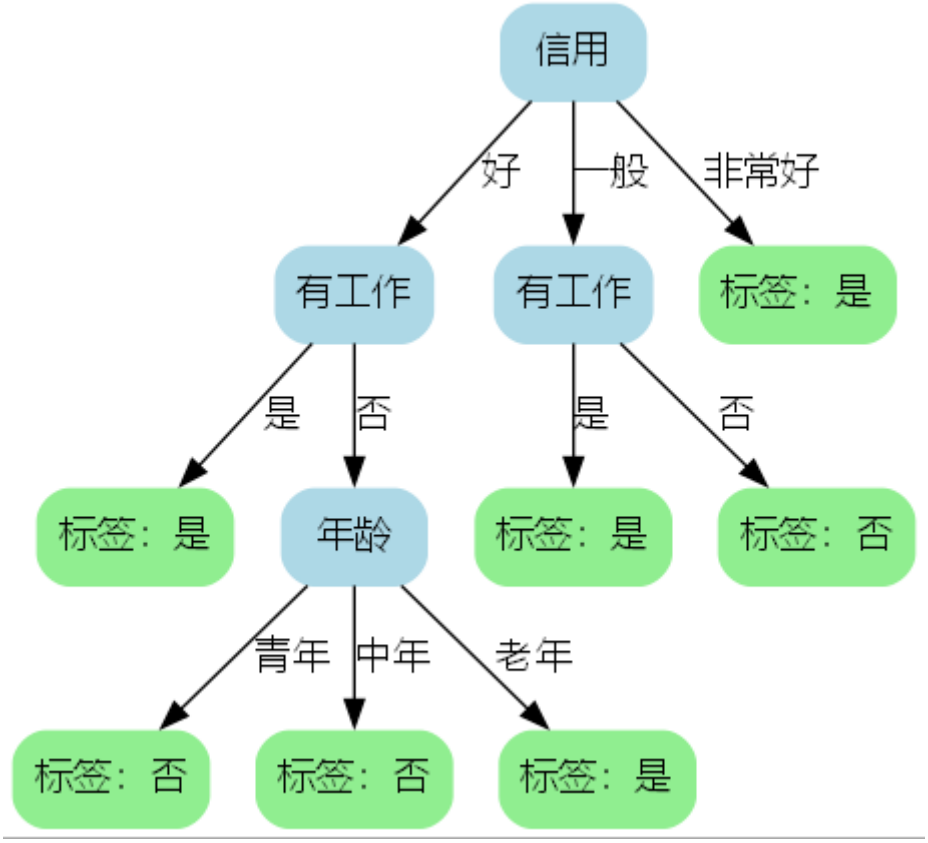


## 第四题 CART 回归树

通过程序进行计算，由于代码篇幅过长，只贴出程序运行结果：

```

================ 第 1 次划分（深度=1）================
当前节点 MSE = 639.979592, 样本数 = 14
```

```

--- 特征【年龄】所有二元划分的 MSE ---
划分 {'青年'} | {'中年', '老年'} → MSE = 482.257143
划分 {'中年'} | {'青年', '老年'} → MSE = 639.673016
划分 {'老年'} | {'青年', '中年'} → MSE = 512.587302
划分 {'青年', '中年'} | {'老年'} → MSE = 512.587302
划分 {'青年', '老年'} | {'中年'} → MSE = 639.673016
划分 {'中年', '老年'} | {'青年'} → MSE = 482.257143

--- 特征【有工作】所有二元划分的 MSE ---
划分 {'是'} | {'否'} → MSE = 571.000000
划分 {'否'} | {'是'} → MSE = 571.000000

--- 特征【有房子】所有二元划分的 MSE ---
划分 {'是'} | {'否'} → MSE = 425.742857
划分 {'否'} | {'是'} → MSE = 425.742857

--- 特征【信用】所有二元划分的 MSE ---
划分 {'好'} | {'一般', '非常好'} → MSE = 621.050595
划分 {'一般'} | {'好', '非常好'} → MSE = 448.885714
划分 {'非常好'} | {'好', '一般'} → MSE = 294.403571
划分 {'好', '一般'} | {'非常好'} → MSE = 294.403571
划分 {'好', '非常好'} | {'一般'} → MSE = 448.885714
划分 {'一般', '非常好'} | {'好'} → MSE = 621.050595

✅ 选择最优特征：信用
✅ 最优划分：左={'非常好'} 右={'好', '一般'}
✅ 最优 MSE = 294.403571

================ 第 2 次划分（深度=2）================
当前节点 MSE = 54.687500, 样本数 = 4

--- 特征【年龄】所有二元划分的 MSE ---
划分 {'中年'} | {'老年'} → MSE = 40.625000
划分 {'老年'} | {'中年'} → MSE = 40.625000

--- 特征【有工作】所有二元划分的 MSE ---
划分 {'是'} | {'否'} → MSE = 29.166667
划分 {'否'} | {'是'} → MSE = 29.166667

--- 特征【有房子】所有二元划分的 MSE ---
划分 {'是'} | {'否'} → MSE = 54.166667
划分 {'否'} | {'是'} → MSE = 54.166667

--- 特征【信用】所有二元划分的 MSE ---

✅ 选择最优特征：有工作
✅ 最优划分：左={'是'} 右={'否'}
✅ 最优 MSE = 29.166667

================ 第 3 次划分（深度=3）================
当前节点 MSE = 0.000000, 样本数 = 1

================ 第 4 次划分（深度=3）================
当前节点 MSE = 38.888889, 样本数 = 3

--- 特征【年龄】所有二元划分的 MSE ---
划分 {'中年'} | {'老年'} → MSE = 37.500000
```

```
划分 {'老年'} | {'中年'} → MSE = 37.500000

--- 特征【有工作】所有二元划分的 MSE ---

--- 特征【有房子】所有二元划分的 MSE ---
划分 {'是'} | {'否'} → MSE = 37.500000
划分 {'否'} | {'是'} → MSE = 37.500000

--- 特征【信用】所有二元划分的 MSE ---

✅ 选择最优特征：年龄
✅ 最优划分：左={'中年'} 右={'老年'}
✅ 最优 MSE = 37.500000

================ 第 5 次划分（深度=4）================
当前节点 MSE = 56.250000, 样本数 = 2

================ 第 6 次划分（深度=4）================
当前节点 MSE = 0.000000, 样本数 = 1

================ 第 7 次划分（深度=2）================
当前节点 MSE = 390.290000, 样本数 = 10

--- 特征【年龄】所有二元划分的 MSE ---
划分 {'青年'} | {'中年', '老年'} → MSE = 346.550000
划分 {'中年'} | {'青年', '老年'} → MSE = 383.085714
划分 {'老年'} | {'青年', '中年'} → MSE = 295.142857
划分 {'青年', '中年'} | {'老年'} → MSE = 295.142857
划分 {'青年', '老年'} | {'中年'} → MSE = 383.085714
划分 {'中年', '老年'} | {'青年'} → MSE = 346.550000

--- 特征【有工作】所有二元划分的 MSE ---
划分 {'是'} | {'否'} → MSE = 216.408333
划分 {'否'} | {'是'} → MSE = 216.408333

--- 特征【有房子】所有二元划分的 MSE ---
划分 {'是'} | {'否'} → MSE = 365.622222
划分 {'否'} | {'是'} → MSE = 365.622222

--- 特征【信用】所有二元划分的 MSE ---
划分 {'好'} | {'一般'} → MSE = 322.283333
划分 {'一般'} | {'好'} → MSE = 322.283333

✅ 选择最优特征：有工作
✅ 最优划分：左={'是'} 右={'否'}
✅ 最优 MSE = 216.408333

================ 第 8 次划分（深度=3）================
当前节点 MSE = 117.187500, 样本数 = 4

--- 特征【年龄】所有二元划分的 MSE ---
划分 {'青年'} | {'中年', '老年'} → MSE = 40.625000
划分 {'中年'} | {'青年', '老年'} → MSE = 112.500000
划分 {'老年'} | {'青年', '中年'} → MSE = 54.166667
划分 {'青年', '中年'} | {'老年'} → MSE = 54.166667
划分 {'青年', '老年'} | {'中年'} → MSE = 112.500000
划分 {'中年', '老年'} | {'青年'} → MSE = 40.625000
```

```
--- 特征【有工作】所有二元划分的 MSE ---

--- 特征【有房子】所有二元划分的 MSE ---
划分 {'是'} | {'否'} → MSE = 116.666667
划分 {'否'} | {'是'} → MSE = 116.666667

--- 特征【信用】所有二元划分的 MSE ---
划分 {'好'} | {'一般'} → MSE = 116.666667
划分 {'一般'} | {'好'} → MSE = 116.666667

✅ 选择最优特征：年龄
✅ 最优划分：左={'青年'} 右={'中年', '老年'}
✅ 最优 MSE = 40.625000

================ 第 9 次划分（深度=4）================
当前节点 MSE = 56.250000, 样本数 = 2

================ 第 10 次划分（深度=4）================
当前节点 MSE = 25.000000, 样本数 = 2

================ 第 11 次划分（深度=3）================
当前节点 MSE = 282.555556, 样本数 = 6

--- 特征【年龄】所有二元划分的 MSE ---
划分 {'青年'} | {'中年', '老年'} → MSE = 200.208333
划分 {'中年'} | {'青年', '老年'} → MSE = 268.333333
划分 {'老年'} | {'青年', '中年'} → MSE = 117.541667
划分 {'青年', '中年'} | {'老年'} → MSE = 117.541667
划分 {'青年', '老年'} | {'中年'} → MSE = 268.333333
划分 {'中年', '老年'} | {'青年'} → MSE = 200.208333

--- 特征【有工作】所有二元划分的 MSE ---

--- 特征【有房子】所有二元划分的 MSE ---

--- 特征【信用】所有二元划分的 MSE ---
划分 {'好'} | {'一般'} → MSE = 223.777778
划分 {'一般'} | {'好'} → MSE = 223.777778

✅ 选择最优特征：年龄
✅ 最优划分：左={'老年'} 右={'青年', '中年'}
✅ 最优 MSE = 117.541667

================ 第 12 次划分（深度=4）================
当前节点 MSE = 306.250000, 样本数 = 2

================ 第 13 次划分（深度=4）================
当前节点 MSE = 23.187500, 样本数 = 4

--- 特征【年龄】所有二元划分的 MSE ---
划分 {'青年'} | {'中年'} → MSE = 9.125000
划分 {'中年'} | {'青年'} → MSE = 9.125000

--- 特征【有工作】所有二元划分的 MSE ---

--- 特征【有房子】所有二元划分的 MSE ---

--- 特征【信用】所有二元划分的 MSE ---
```

```
划分 {'好'} | {'一般'} → MSE = 15.625000
划分 {'一般'} | {'好'} → MSE = 15.625000

✅ 选择最优特征：年龄
✅ 最优划分：左={'青年'} 右={'中年'}
✅ 最优 MSE = 9.125000

================ 第 14 次划分（深度=5）================
当前节点 MSE = 2.250000, 样本数 = 2

================ 第 15 次划分（深度=5）================
当前节点 MSE = 16.000000, 样本数 = 2

================ 最终 CART 回归树结构 ================
特征：信用
  左侧取值：{'非常好'}
  右侧取值：{'好', '一般'}
 特征：有工作
   左侧取值：{'是'}
   右侧取值：{'否'}
   → 叶子：预测值 = 90.00
   特征：年龄
     左侧取值：{'中年'}
     右侧取值：{'老年'}
     → 叶子：预测值 = 77.50
     → 叶子：预测值 = 80.00
 特征：有工作
   左侧取值：{'是'}
   右侧取值：{'否'}
   特征：年龄
     左侧取值：{'青年'}
     右侧取值：{'中年', '老年'}
     → 叶子：预测值 = 47.50
     → 叶子：预测值 = 65.00
   特征：年龄
     左侧取值：{'老年'}
     右侧取值：{'青年', '中年'}
     → 叶子：预测值 = 47.50
     特征：年龄
       左侧取值：{'青年'}
       右侧取值：{'中年'}
       → 叶子：预测值 = 16.50
       → 叶子：预测值 = 24.00
✅ 已输出图片：CART_Regression_Full.png

================ 测试样本预测 ================
输入样本： ['中年', '否', '是', '一般']
预测投资金额： 24.0
```

其中，对测试样本预测的投资金额为：24(万元)

以下为回归树的图片：

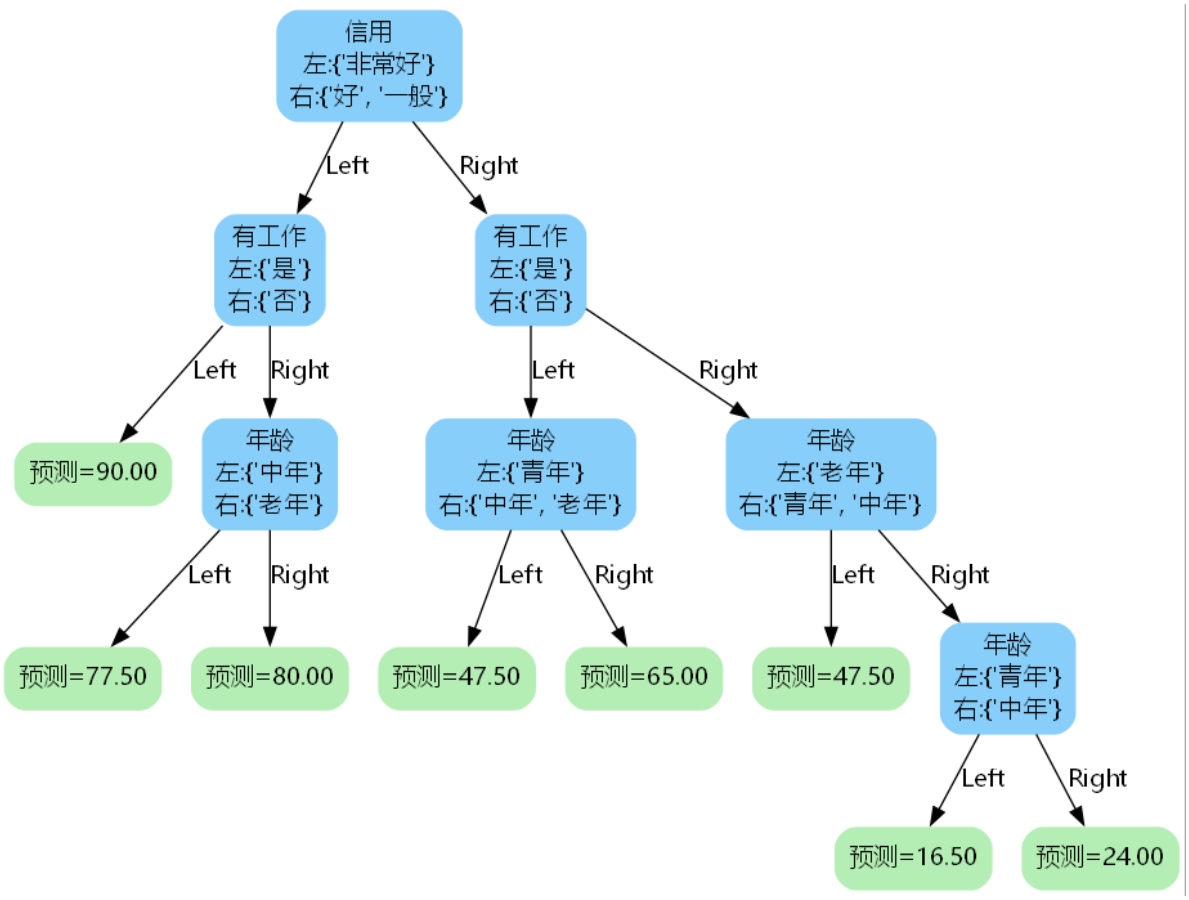


以下为手工计算第一次划分（信用）的 MSE的过程：

把目标值按信用分组：

一般：15，55，20，30

好：18，40，28，60，65，70

非常好：70，85，80，90

$MSE_{一般} = \frac{950}{4} = 237.50$，$MSE_{好} = \frac{2272.833}{6} = 378.8056$

$MSE_{非常好} = \frac{218.75}{4} = 54.6875$，$MSE_{好\cup非常好} = \frac{5334.40}{10} = 533.44$

$MSE_{一般\cup非常好} = \frac{6421.875}{8} = 802.734375$，$MSE_{一般\cup好} = \frac{3092.90}{10} = 390.29$

三种情形：

① 左 = {一般}，右 = {好，非常好}

$MSE = \frac{4}{14} \cdot 237.50 + \frac{10}{14} \cdot 533.44 = 448.8857$

② 左 = {好}，右 = {一般，非常好}

$MSE = \frac{6}{14} \cdot 378.8056 + \frac{8}{14} \cdot 802.734375 = 621.0506$

③ 左 = {非常好}，右 = {一般，好}

$MSE = \frac{4}{14} \cdot 54.6875 + \frac{10}{14} \cdot 390.29 = 294.4036$

③的MSE最小，最优划分为 {非常好} vs {一般，好}