损失函数

回顾：图像识别的挑战

Viewpoint 视角

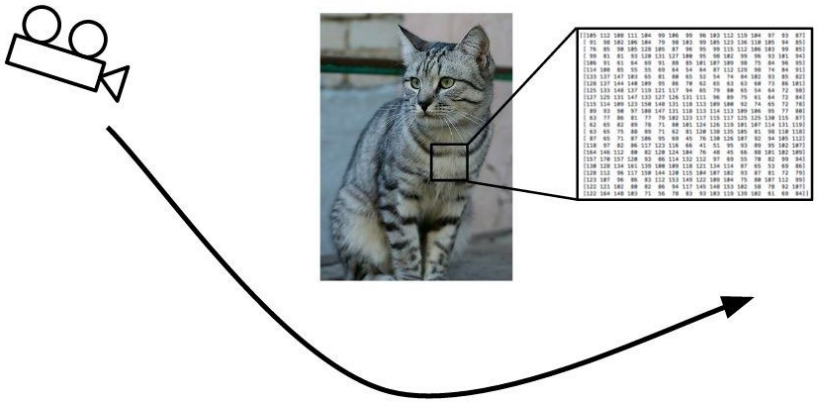

Illumination 光照

This image is CC0 1.0 public domain

Deformation 变形

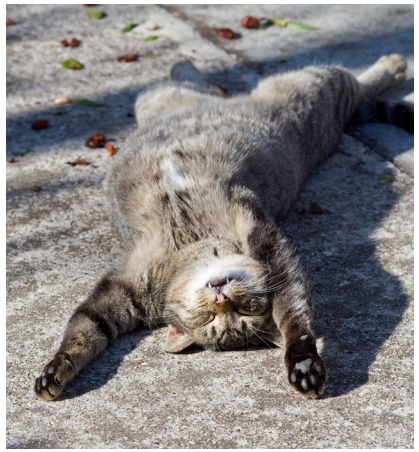

This image by Umberto Salvagnin is licensed under CC-BY 2.0

Occlusion 遮挡

This image by jonsson is licensed under CC-BY 2.0

Clutter 杂乱

This image is CC0 1.0 public domain

Intraclass Variation 类内变化

This image is CC0 1.0 public domain

回顾：数据驱动方法， KNN

1-NN classifier

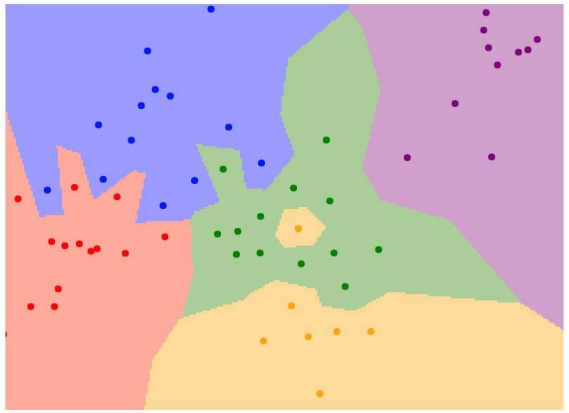

5-NN classifier

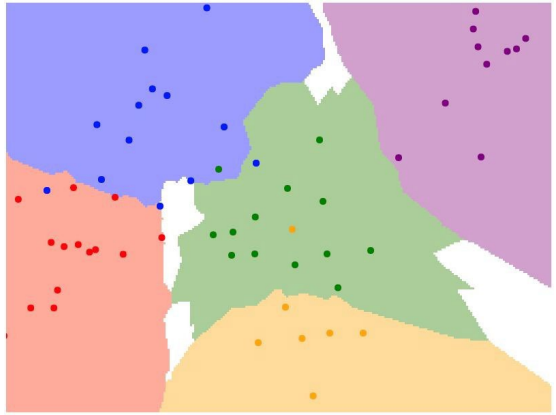

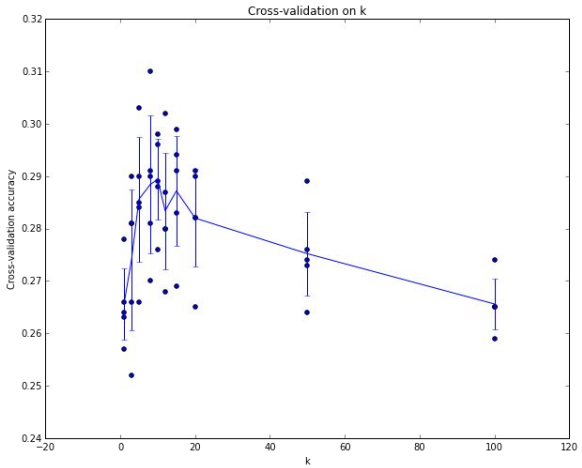

train	test

train	validation	test

回顾：线性分类器

图片

包含**32x32x3**数字的数组
(总共3072个数字)

→ f(**x**,**W**) → **10个数字表示类别得分。**

↑

W

参数或权重

$$f(x,W) = Wx + b$$

代数视角

f(x,W) = Wx

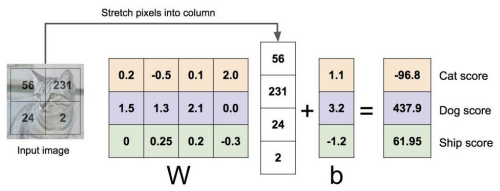

可视化视角

One template per class

几何视角

Hyperplanes cutting up space

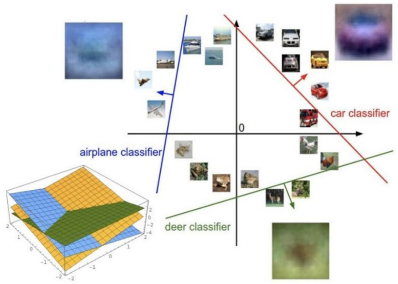

Class 1:
1 <= L2 norm <= 2

Class 2:
其他

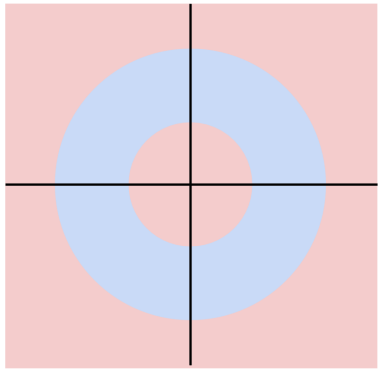

Class 1:
三个圆

Class 2:
其他

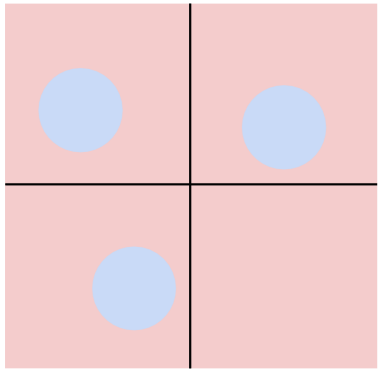

找出函数的三步骤

设定范围

Model

订出候选函数的集合

设定标准

Loss

订出「评价函数好坏」的标准。

达成目标

找出最好的函数 ➡ 最优化 (Optimization)

回顾：线性分类器

airplane	-3.45	-0.51	3.42
automobile	-8.87	**6.04**	4.64
bird	0.09	5.31	2.65
cat	**2.9**	-4.22	5.1
deer	4.48	-4.19	2.64
dog	8.02	3.58	5.55
frog	3.78	4.49	**-4.34**
horse	1.06	-4.37	-1.5
ship	-0.36	-2.09	-4.79
truck	-0.72	-2.93	6.14

Cat image by Nikita is licensed under CC-BY 2.0; Car image is CC0 1.0 public domain; Frog image is in the public domain

TODO:

1. 定义一个损失函数，用于**量化**我们对训练数据中分数的**不满意程度**。

2. 提出一种有效地找到**最小化损失函数**的参数的方法。（**优化**）

3. 如何解决**非线性决策边界**问题

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

损失函数用于衡量我们当前分类器的性能有多好

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**

损失函数用于衡量我们当前分类器的性能有多好

给定一个数据集

$$\{(x_i, y_i)\}_{i=1}^{N}$$

x_i 是图片
y_i 是标签 (整数)

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**

损失函数用于衡量我们当前分类器的性能有多好

给定一个数据集的样本

$$\{(x_i, y_i)\}_{i=1}^{N}$$

x_i 是图片
y_i 是标签 (整数)

数据集上的损失是样本上损失的平均值：

$$L = \frac{1}{N} \sum_i L_i(f(x_i, W), y_i)$$

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \begin{cases} 0 & \text{if } s_{y_i} \geq s_j + 1 \\ s_j - s_{y_i} + 1 & \text{otherwise} \end{cases}$$

$$= \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**

多类支持向量机损失:

“合页损失函数”

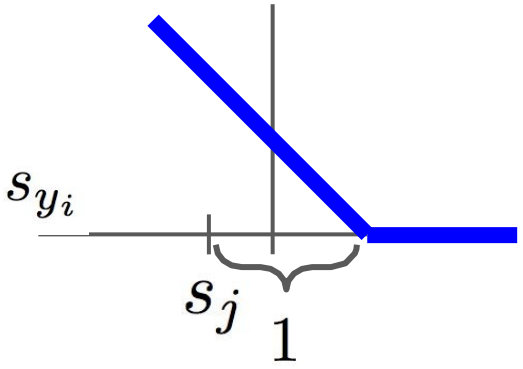

$$L_i = \sum_{j \neq y_i} \begin{cases} 0 & \text{if } s_{y_i} \geq s_j + 1 \\ s_j - s_{y_i} + 1 & \text{otherwise} \end{cases}$$

$$= \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$\boxed{L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)}$$

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9		

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

= max(0, 5.1 - 3.2 + 1)
+max(0, -1.7 - 3.2 + 1)
= max(0, 2.9) + max(0, -3.9)
= 2.9 + 0
= 2.9

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

= max(0, 1.3 - 4.9 + 1)
+max(0, 2.0 - 4.9 + 1)
= max(0, -2.6) + max(0, -1.9)
= 0 + 0
= 0

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$

来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

= max(0, 2.2 - (-3.1) + 1)

+max(0, 2.5 - (-3.1) + 1)

= max(0, 6.3) + max(0, 6.6)

= 6.3 + 6.6

= 12.9

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$\boxed{L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)}$$

整个数据集上的损失是平均值:

$$L = \frac{1}{N} \sum_{i=1}^{N} L_i$$

L = (2.9 + 0 + 12.9)/3
= **5.27**

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Q: 如果汽车的分数稍微改变会发生什么?

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9** → **5.0**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Q: 如果汽车的分数稍微改变会发生什么?

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9** → **5.0**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

= max(0, 1.3 – 5.0 + 1)
+max(0, 2.0 – 5.0 + 1)
= max(0, -2.7) + max(0, -2.0)
= 0 + 0
= 0

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9** → **5.0**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Q: 如果汽车的分数稍微改变会发生什么?

还是为0!

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Q2: 最小/大的
loss值是多少?

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Q2: 最小/大的loss值是多少?

$(0, +\infty)$

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Q3: 初始化时W很小，因此所有s≈0，这时loss值是多少?

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Q3: 初始化时W很小，因此所有s≈0，这时loss值是多少?

类别数 - 1

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Q4: 如果我们对所有类别都求和呢? (包括 j = y_i)

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$

来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

= max(0, 5.1 - 3.2 + 1)
+max(0, -1.7 - 3.2 + 1)
+max(0,3.2-3.2+1)
= max(0, 2.9) + max(0, -3.9)
+max(0,1)
= 2.9 + 0 +1
= 3.9

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Q5: 如果我们用平均值而不是总和会怎么样?

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat car	**3.2**	1.3	2.2
frog	5.1	**4.9**	2.5
Losses:	-1.7	2.0	**-3.1**
	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Q5: 如果我们用平均值而不是总和会怎么样？ L-> L/N

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$\boxed{L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)}$$

Q6: 如果我们用平方会怎么样?

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)^2$$

假设：有3个训练样本和3个类别。
使用某个W来计算分数 $f(x, W) = Wx$

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	2.9	0	12.9

多类支持向量机损失:

给定一个样本 (x_i, y_i)

x_i 是图片

y_i 是代表正确类别的标签（整数）

通过公式 $s = f(x_i, W)$
来计算不同分类类别的分值:

SVM的损失函数定义如下:

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

Q6: 如果我们用平方会怎么样?

错误分类的损失函数值的会更大

多类支持向量机损失： 代码示例

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

```
def L_i_vectorized(x, y, W):
  scores = W.dot(x)
  margins = np.maximum(0, scores - scores[y] + 1)
  margins[y] = 0
  loss_i = np.sum(margins)
  return loss_i
```

案例分析

线性分类

二维特征空间的图像分类

- 背景
  - 我们处理一个三分类问题，目标是根据两个特征（平均亮度和边缘数量）来对图片中的动物进行分类。动物的类别包括：猫（+1）、狗（-1）和兔子（0）。我们将通过构建一个线性分类器来区分这三类动物。
- 任务目标
  - 构建一个线性分类器，使用矩阵乘法和加法来表示决策过程。计算每个样本的预测值，并通过**最大化预测值**来确定分类结果。通过SVM损失函数来评估分类器的性能。
- 数据集
  - 特征1（$x1$）：图像的平均亮度
  - 特征2（$x2$）：图像的边缘数量
  - 类别：猫、狗、兔子

二维特征空间的图像分类

样本	x_1	x_2	真实类别
样本1	0.8	1.5	猫
样本2	1.0	2.0	狗
样本3	1.0	1.0	兔子
样本4	0.6	1.2	猫
样本5	1.1	2.2	狗
样本6	1.5	0.5	兔子

二维特征空间的图像分类

线性分类器的构建

线性分类器可以将每个样本的特征值与分类权重相乘，得到一组预测值。这些预测值将决定样本属于哪个类别。

线性分类器公式：

对于每个样本 $x = [x_1, x_2]$，分类器的计算过程如下：

$$y = W \cdot x + b$$

其中：

- W 是分类器的权重矩阵，包含三个类别（猫、狗、兔子）对应的权重；
- $x = [x_1, x_2]$ 是样本的特征向量（平均亮度和边缘数量）；
- b 是分类器的偏置向量，包含每个类别的偏置项。

权重矩阵 W：

$$W = \begin{bmatrix} 1 & -1 \\ -1 & 1 \\ 1 & 0 \end{bmatrix}$$

- 第一行对应“猫”；
- 第二行对应“狗”；
- 第三行对应“兔子”。

偏置向量 b：

$$b = \begin{bmatrix} 0 \\ 0.5 \\ 0.2 \end{bmatrix}$$

- 第一项 $b_1 = 0$ 对应“猫”；
- 第二项 $b_2 = 0.5$ 对应“狗”；
- 第三项 $b_3 = 0.2$ 对应“兔子”。

二维特征空间的图像分类

分类决策过程

通过矩阵乘法和加法，分类器会计算出三个预测值 y_1、y_2、y_3，分别对应每个类别（猫、狗、兔子）。**最大值**表示分类结果，样本将被分配到具有最大预测值的类别。

分类规则：

- 如果 y_1 最大，样本分类为“猫”；
- 如果 y_2 最大，样本分类为“狗”；
- 如果 y_3 最大，样本分类为“兔子”。

二维特征空间的图像分类

- **任务**
  - 根据给出的权重和偏置，对每个样本计算出当前分类器预测的类别
  - SVM损失函数计算：对每个样本使用SVM多分类损失函数计算分类损失。计算每个样本的损失值，并计算所有样本的平均损失。
  - 参数调整：手动调整权重 $w1$ 、$w2$和偏置 b，通过改变权重或偏置的值，优化模型，使得分类更准确，损失更小。可以观察决策边界的变化，以及这些变化如何影响分类的准确性。

二维特征空间的图像分类

- 参数调整提示：
  - 优化模型性能观察当前模型表现计算每个样本的预测值、预测类别和损失值，找出分类错误的样本。
  - 调整权重 $w1$ 和 $w2$
    - 增大 $w1$：提高特征1（亮度）的重要性。
    - 减小 $w2$：降低特征2（如边缘数量）的影响。
  - 调整偏置 b
    - 增大 b：让模型更倾向于某一类。
    - 减小 b：使分类器更加严格。
  - 观察预测结果和损失变化每次调整后重新计算，记录预测值和损失。如果损失减少，说明调整有效；否则，尝试反向调整。

$$f(x, W) = Wx$$

$$L = \frac{1}{N} \sum_{i=1}^{N} \sum_{j \neq y_i} \max(0, f(x_i; W)_j - f(x_i; W)_{y_i} + 1)$$

E.g.假设我们找到一个使L = 0的W。这个W是唯一的吗？

$$f(x, W) = Wx$$

$$L = \frac{1}{N}\sum_{i=1}^{N}\sum_{j \neq y_i} \max(0, f(x_i; W)_j - f(x_i; W)_{y_i} + 1)$$

E.g.假设我们找到一个使L = 0的W。这个W是唯一的吗？

No! 2W 也能使得L = 0!

$$f(x, W) = Wx$$

$$L = \frac{1}{N}\sum_{i=1}^{N}\sum_{j \neq y_i} \max(0, f(x_i; W)_j - f(x_i; W)_{y_i} + 1)$$

E.g.假设我们找到一个使L = 0的W。这个W是唯一的吗？

No! 2W 也能使得L = 0!

W和2W我们应该原则哪一个？

正则化

$$L(W) = \underbrace{\frac{1}{N}\sum_{i=1}^{N} L_i(f(x_i, W), y_i)}$$

数据损失:模型预测应该与训练数据匹配

正则化

$$L(W) = \underbrace{\frac{1}{N}\sum_{i=1}^{N} L_i(f(x_i, W), y_i)} + \underbrace{\lambda R(W)}$$

数据损失:模型预测应该与训练数据匹配

正则化:防止模型在训练数据上做得太好

正则化

λ =正则化强度(超参数)

$$L(W) = \underbrace{\frac{1}{N}\sum_{i=1}^{N} L_i(f(x_i, W), y_i)} + \underbrace{\lambda R(W)}$$

数据损失:模型预测应该与训练数据匹配

正则化:防止模型在训练数据上做得太好

正则化

λ =正则化强度(超参数)

$$L(W) = \underbrace{\frac{1}{N}\sum_{i=1}^{N} L_i(f(x_i, W), y_i)}_{\text{数据损失:模型预测应该与训练数据匹配}} + \underbrace{\lambda R(W)}_{\text{正则化:防止模型在训练数据上做得太好}}$$

简单的:

<u>L2 正则化:</u> $R(W) = \sum_k \sum_l W_{k,l}^2$

L1 正则化: $R(W) = \sum_k \sum_l |W_{k,l}|$

弹性网络 (L1 + L2): $R(W) = \sum_k \sum_l \beta W_{k,l}^2 + |W_{k,l}|$

正则化

λ =正则化强度(超参数)

$$L(W) = \underbrace{\frac{1}{N}\sum_{i=1}^{N} L_i(f(x_i, W), y_i)}_{\text{数据损失:模型预测应该与训练数据匹配}} + \underbrace{\lambda R(W)}_{\text{正则化:防止模型在训练数据上做得太好}}$$

简单的:

<u>L2 正则化:</u> $R(W) = \sum_k \sum_l W_{k,l}^2$

L1 正则化: $R(W) = \sum_k \sum_l |W_{k,l}|$

弹性网络 (L1 + L2): $R(W) = \sum_k \sum_l \beta W_{k,l}^2 + |W_{k,l}|$

更复杂的:

Dropout 随机失活

Batch normalization 批归一化

Stochastic depth, fractional pooling, etc

随机深度，分数池化，等

正则化

λ =正则化强度(超参数)

$$L(W) = \underbrace{\frac{1}{N}\sum_{i=1}^{N} L_i(f(x_i, W), y_i)} + \underbrace{\lambda R(W)}$$

数据损失:模型预测应该与训练数据匹配

正则化:防止模型在训练数据上做得太好

为什么正则化?

- 防止过拟合
- 在权重上表达偏好
- 提高泛化能力：使模型变得简单，以便它能在测试数据上更稳定

正则化:表达偏好

$$x = [1, 1, 1, 1]$$

$$w_1 = [1, 0, 0, 0]$$

$$w_2 = [0.25, 0.25, 0.25, 0.25]$$

$$w_1^T x = w_2^T x = 1$$

L2 正则化

$$R(W) = \sum_k \sum_l W_{k,l}^2$$

正则化:表达偏好

$$x = [1, 1, 1, 1]$$

$$w_1 = [1, 0, 0, 0]$$

$$w_2 = \boxed{[0.25, 0.25, 0.25, 0.25]}$$

$$w_1^T x = w_2^T x = 1$$

L2 正则化

$$R(W) = \sum_k \sum_l W_{k,l}^2$$

L2正则化倾向于“分散”权重

正则化：更喜欢更简单的模型

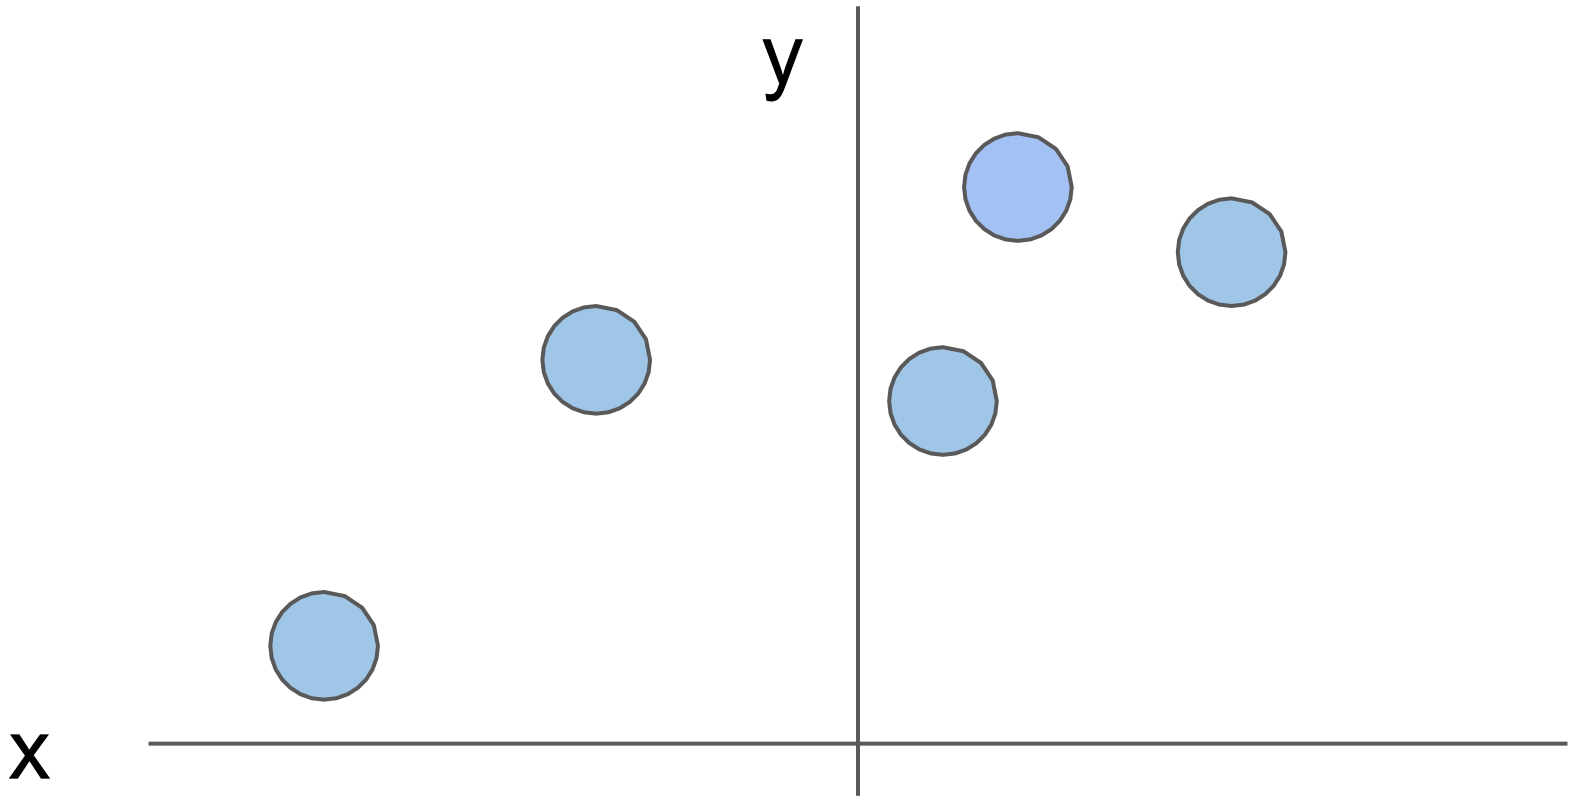

正则化：更喜欢更简单的模型

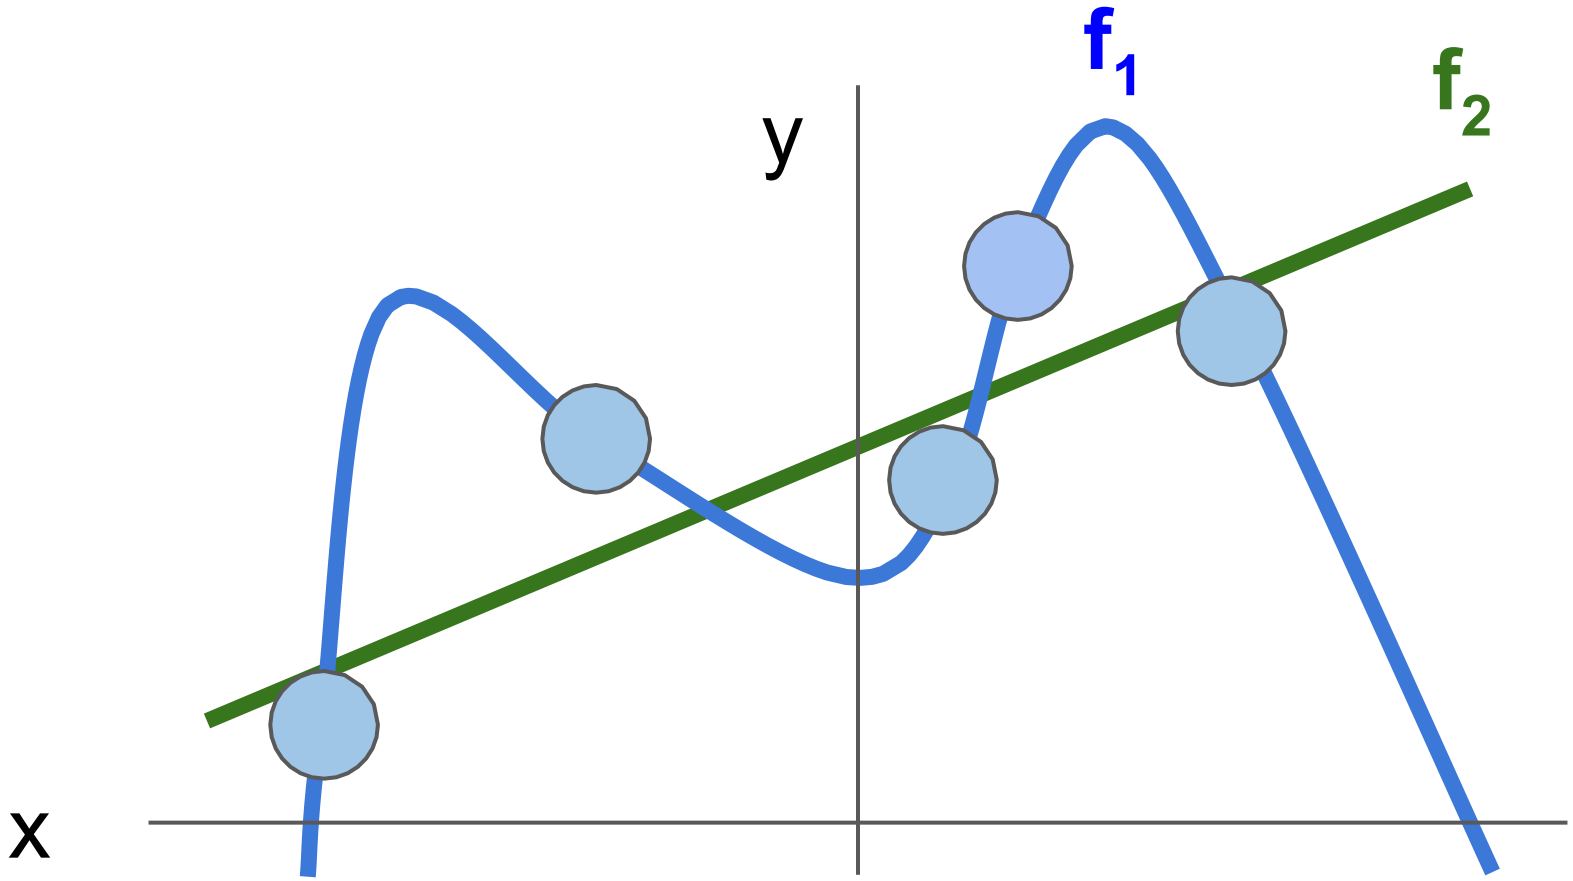

正则化：更喜欢更简单的模型

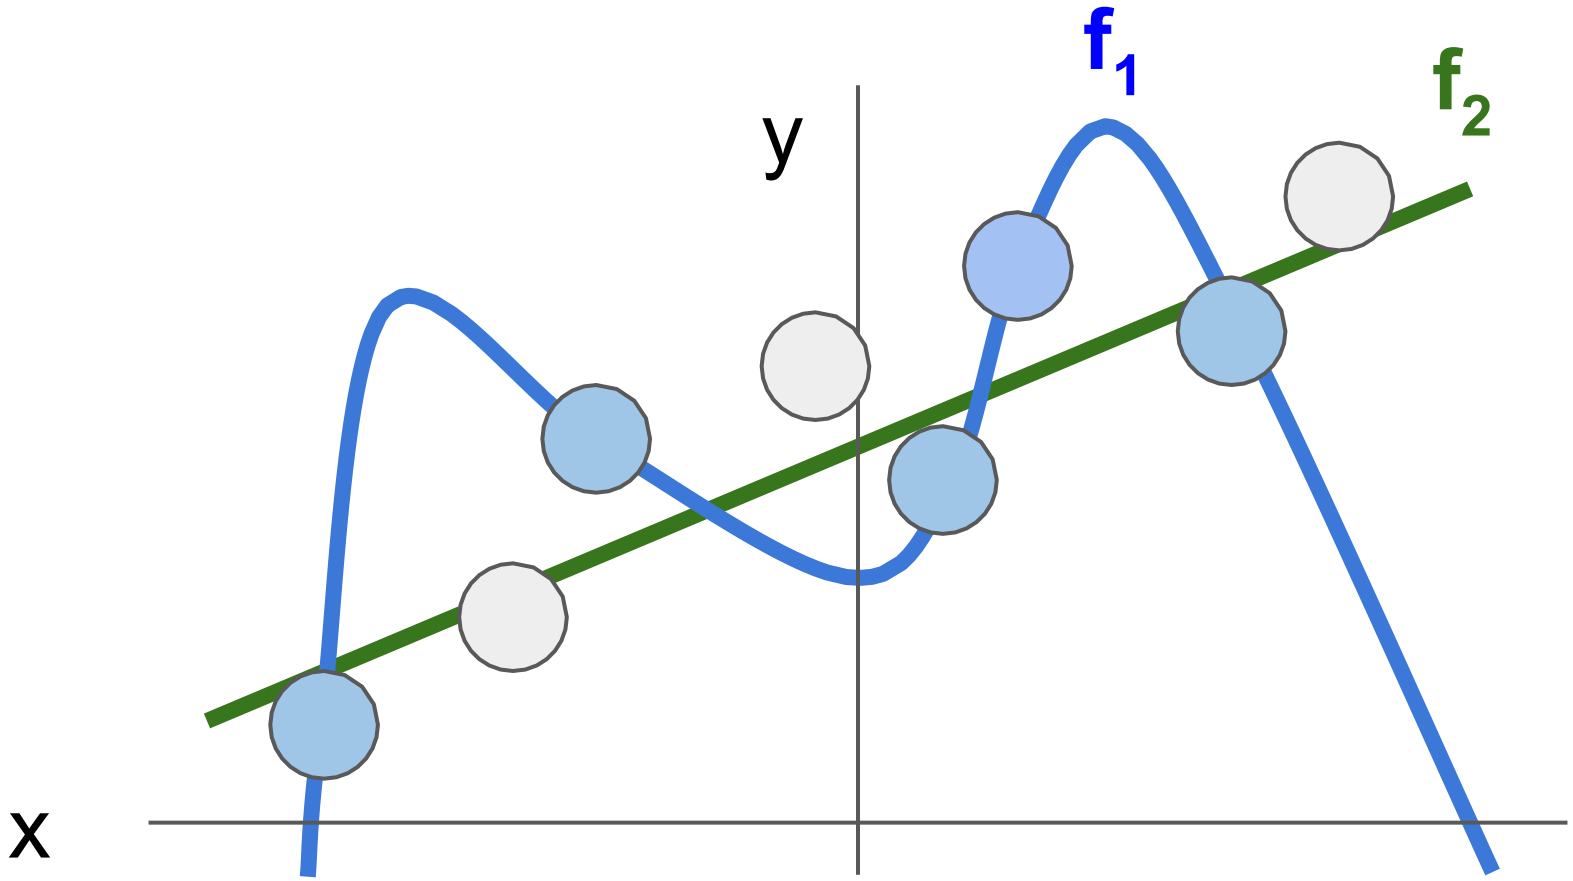

正则化旨在抑制过度拟合数据，以防止拟合数据中的噪音。

自然对数和自然指数函数

e 是自然常数，2.7182818…

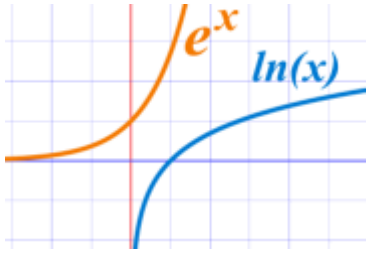

- 自然指数函数：$y = e^x$
- 自然对数函数：$x = log_e(y) = \ln(y)$
- 互为反函数

自然对数

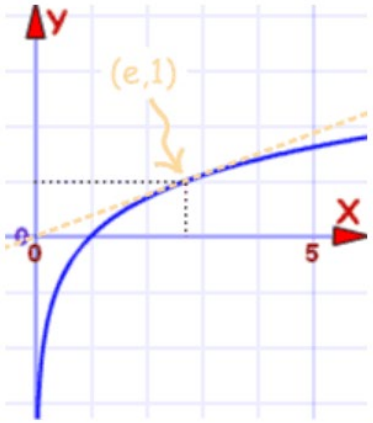

f(x) = ln(x)的图

穿过 (1,0) 和 (e,1)

自然指数函数

f(x) = e^x的图

穿过 (0,1) 和 (1,e)

它们是同一条曲线，不过**x轴 和 y轴 对调了。**

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

cat	**3.2**
car	5.1
frog	-1.7

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

		概率
cat	**3.2**	→ [0,1]
car	5.1	→ [0,1]
frog	-1.7	→ [0,1]

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。 Softmax函数

$$s = f(x_i; W)$$

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

cat	**3.2**
car	5.1
frog	-1.7

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

$$s = f(x_i; W)$$

Softmax函数

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

cat	**3.2**	exp →	**24.5**
car	5.1		164.0
frog	-1.7		0.18

未归一化的概率

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

$$s = f(x_i; W)$$

Softmax函数

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

			概率>= 0		概率和为1
cat	**3.2**	exp	**24.5**	normalize	**0.13**
car	5.1	→	164.0	→	0.87
frog	-1.7		0.18		0.00
			未归一化的概率		概率

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

$$s = f(x_i; W)$$

Softmax函数

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

	未归一化的 logits	exp	概率>= 0 未归一化的概率	normalize	概率和为1 概率
cat	**3.2**	→	**24.5**	→	**0.13**
car	5.1		164.0		0.87
frog	-1.7		0.18		0.00

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

$$s = f(x_i; W)$$

Softmax函数

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

	未归一化的 logits	exp →	概率>= 0 未归一化的概率	normalize →	概率和为1 概率	→
cat	**3.2**		**24.5**		**0.13**	L_i = -log(0.13) = **2.04**
car	5.1		164.0		0.87	
frog	-1.7		0.18		0.00	

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

$$s = f(x_i; W)$$

Softmax函数

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

	未归一化的logits	exp →	概率>= 0 未归一化的概率	normalize →	概率和为1 概率
cat	**3.2**		**24.5**		**0.13**
car	5.1		164.0		0.87
frog	-1.7		0.18		0.00

交叉熵损失函数

$$L_i = -\log P(Y = y_i | X = x_i)$$

→ L_i = -log(0.13)
= **2.04**

这里的log是以**e**为底的对数函数
e 是自然常数，2.7182818…
P=**1**时，**L=0**

图形计算器 - GeoGebra

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

cat	**3.2**	1.3	2.2
car	5.1	**4.9**	2.5
frog	-1.7	2.0	**-3.1**
Losses:	**2.04**		

$$s = f(x_i; W)$$

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

交叉熵损失函数

$$L_i = -\log P(Y = y_i | X = x_i)$$

Desmos | 科学计算器

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

$$\boxed{s = f(x_i; W)}$$

Softmax函数

$$\boxed{P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}}$$

最大化正确类别的概率

$$L_i = -\log P(Y = y_i | X = x_i)$$

合并后

$$L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$$

cat car	**3.2**
frog	5.1
	-1.7

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

$$s = f(x_i; W)$$

Softmax函数

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

最大化正确类别的概率

$$L_i = -\log P(Y = y_i | X = x_i)$$

合并后

$$L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$$

cat	**3.2**
car	5.1
frog	-1.7

Q: L_i的最小/大值是多少?

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

$$\boxed{s = f(x_i; W)}$$

Softmax函数

$$\boxed{P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}}$$

cat	**3.2**
car	5.1
frog	-1.7

最大化正确类别的概率

$$L_i = -\log P(Y = y_i | X = x_i)$$

合并后

$$L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$$

Q: L_i的最小/大值是多少?

A: 最小值 0, 最大值 无穷大

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

$$s = f(x_i; W)$$

Softmax函数

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

最大化正确类别的概率

$$L_i = -\log P(Y = y_i | X = x_i)$$

合并后

$$L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$$

cat	**3.2**
car	5.1
frog	-1.7

Q2:初始化时，所有s近似相等;损失是什么?

Softmax分类器（多分类逻辑回归）

希望将原始分类器分数解释为**概率**。

$$\boxed{s = f(x_i; W)}$$

Softmax函数

$$\boxed{P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}}$$

最大化正确类别的概率

$$L_i = -\log P(Y = y_i | X = x_i)$$

合并后

$$L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$$

cat	**3.2**
car	5.1
frog	-1.7

Q2:初始化时，所有s近似相等;损失是什么?
A: -log(1/C)=log(C), eg log(10) ≈ 2.3

交叉熵 vs. SVM

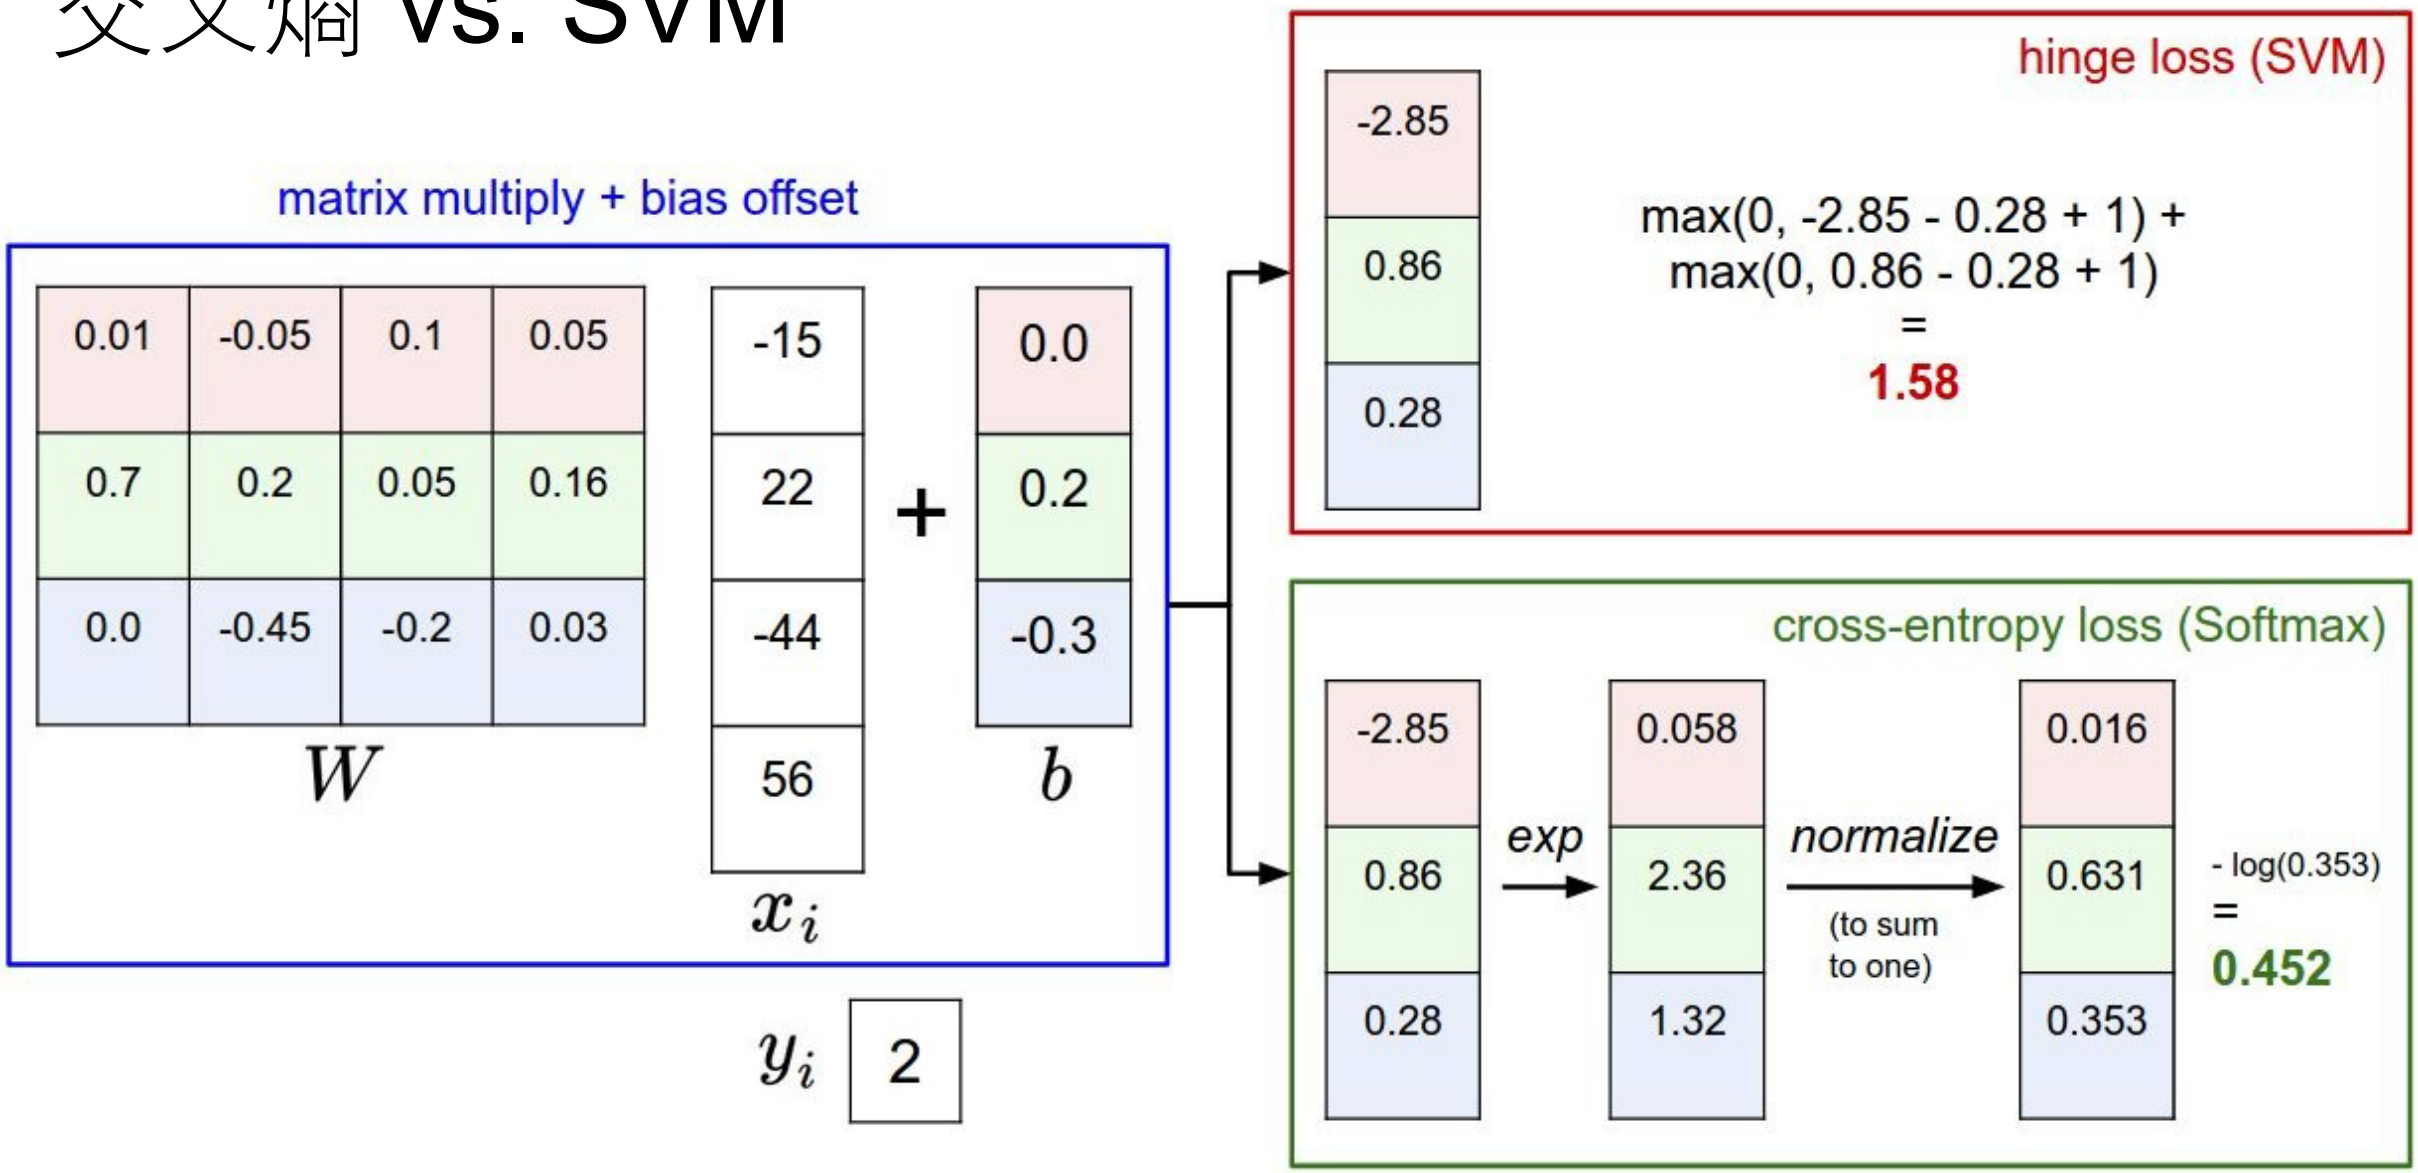
matrix multiply + bias offset
0.01
-0.05
0.1
0.05
0.7
0.2
0.05
0.16
0.0
-0.45
-0.2
0.03
W
-15
22
-44
56
x_i
+
0.0
0.2
-0.3
b
y_i
2
hinge loss (SVM)
-2.85
0.86
0.28
max(0, -2.85 - 0.28 + 1) +
max(0, 0.86 - 0.28 + 1)
=
1.58
cross-entropy loss (Softmax)
-2.85
0.86
0.28
exp
0.058
2.36
1.32
normalize
(to sum
to one)
0.016
0.631
0.353
- log(0.353)
=
0.452

交叉熵 vs. SVM

$$L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$$

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

交叉熵 vs. SVM

$$L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$$

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$

假设分数如下: [10, -2, 3]
[10, 9, 9]
[10, -100, -100]
and $\boxed{y_i = 0}$

Q: 使用两种损失函数，在这三种情况下，损失会发生什么变化?

回顾

- 我们有一些数据 (x,y)
- 我们有一个分类器: $s = f(x; W) \overset{\text{e.g.}}{=} Wx$
- 我们有一个损失函数:

Softmax

$$L_i = -\log\left(\frac{e^{s_{y_i}}}{\sum_j e^{s_j}}\right)$$

SVM

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + 1)$$
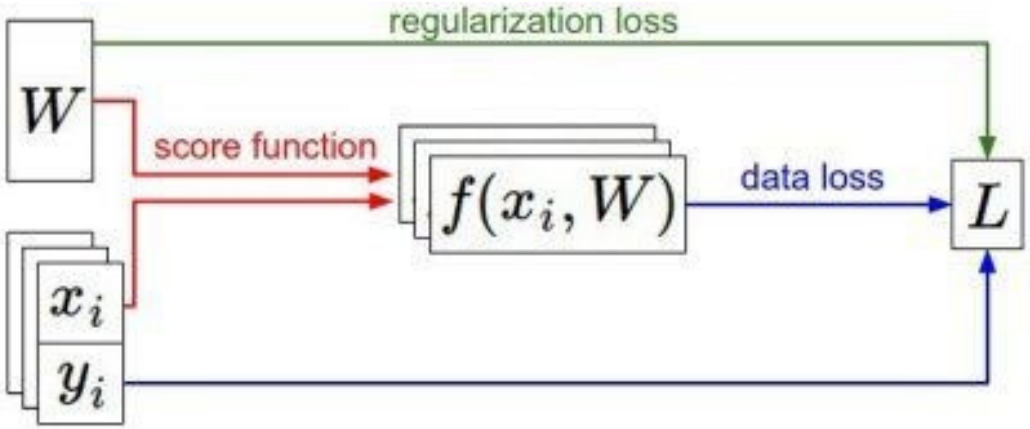
$$L = \frac{1}{N} \sum_{i=1}^{N} L_i + R(W)$$ Full loss