一、KNN 分类计算题

编号	特征	类别
A	(1,2)	0
B	(2,3)	0
C	(3,3)	1
D	(5,2)	1
E	(4,0)	1

测试样本：$x = (3, 2)$, 使用 $K = 3$，欧氏距离

任务：

1. 计算每个点距离

$$d_{x,A} = 2 \quad d_{x,B} = \sqrt{2} \quad d_{x,C} = 1 \quad d_{x,D} = 2 \quad d_{x,E} = \sqrt{5}$$

2. 找出前 3 个近邻

前 3 个近邻为 C, B, A

3. 根据多数投票判断类别

类别为 1

4. 思考：若 $K = 5$ 呢？若 $K = 1$ 呢？

若 $K = 5$ 则类别为 1，若 $K = 1$ 则类别为 1

二、损失函数计算题

1. $Softmax$ + 交叉熵计算

输入：模型得分 $s = [2.0, 1.0, 0.1]$，标签为类别 0

任务：

$Softmax$ 输出

$$\hat{y} = \begin{bmatrix} \frac{e^2}{e^2+e^1+e^{0.1}} & \frac{e^1}{e^2+e^1+e^{0.1}} & \frac{e^{0.1}}{e^2+e^1+e^{0.1}} \end{bmatrix}^\top$$

交叉熵损失

$$L = -log(\frac{e^2}{e^2 + e^1 + e^{0.1}}) = log(e^2 + e^1 + e^{0.1}) - 2$$

思考：若标签改为类别 2，会发生什么变化？

$$L = -log(\frac{e^{0.1}}{e^2 + e^1 + e^{0.1}}) = log(e^2 + e^1 + e^{0.1}) - 0.1$$

损失会变大

2. $SVMhingeloss$ 计算

输入得分 $s = [3.0,\ 1.5,\ -0.5]$，标签为类别 0

任务：

写出每个 $margin$

$margin$ 计算公式如下：

$$margin_j = s_j - s_y + 1(j \neq y)$$

$margin$ 计算过程如下：

$$\begin{gathered} margin_0 = 0 \\ margin_1 = 1.5 - 3.0 + 1 = -0.5 \\ margin_2 = -0.5 - 3.0 + 1 = -2.5 \\ margin = [0,\ -0.5,\ -2.5] \end{gathered}$$

计算 SVM 损失

SVM 损失函数公式如下：

$$L_j = max(0,\ margin_j)$$

SVM 损失如下：

$$L = [0,\ 0,\ 0]$$

三、梯度下降与参数更新题

1. 单变量线性回归

输入 $x = 1$, 目标 $y = 4$，参数 $w_0 = 0, w_1 = 0$，使用 MSE 损失。

求预测值、损失值、梯度，并执行一轮参数更新（$\alpha = 0.1$）。

预测值如下：

$$\hat{y} = w_0 + w_1 x = 0 + 0 \times 1 = 0$$

损失值如下：

$$L = \frac{1}{2}\ (\hat{y} - y)^2 = \frac{1}{2}\ (0 - 4)^2 = 8$$

梯度计算如下：

$$\begin{gathered} \frac{\partial L}{\partial w_0} = \frac{\partial L}{\partial \hat{y}}\ \cdot\ \frac{\partial \hat{y}}{\partial w_0} = (\hat{y} - y)\ \cdot\ 1 = (-4)\ \cdot\ 1 = -4 \\ \frac{\partial L}{\partial w_1} = \frac{\partial L}{\partial \hat{y}}\ \cdot\ \frac{\partial \hat{y}}{\partial w_1} = (\hat{y} - y)\ \cdot\ x = (-4)\ \cdot\ 1 = -4 \end{gathered}$$

梯度向量如下：

$$\nabla L = [-4, -4]$$

参数更新过程如下：

$$w_{0(new)} = w_{0(old)} - \alpha \cdot \frac{\partial L}{\partial w_0} = 0 - 0.1 \cdot (-4) = 0.4$$
$$w_{1(new)} = w_{1(old)} - \alpha \cdot \frac{\partial L}{\partial w_1} = 0 - 0.1 \cdot (-4) = 0.4$$

新的参数如下：

$$w_0 = 0.4, \quad w_1 = 0.4$$

2. 多变量线性模型

$x = [2, 3], w_0 = 0, w_1 = 1, w_2 = -1, y = 1$

使用 MSE，求梯度向量和新的参数值（$\alpha = 0.05$）。

预测值如下：

$$\hat{y} = w_0 + w_1 x_1 + w_2 x_2 = 0 + 1 \cdot 2 + (-1) \cdot 3 = -1$$

损失值如下：

$$L = \frac{1}{2}(\hat{y} - y)^2 = \frac{1}{2}(-1 - 1)^2 = 2$$

梯度计算如下：

$$\frac{\partial L}{\partial w_0} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial w_0} = (\hat{y} - y) \cdot 1 = (-2) \cdot 1 = -2$$
$$\frac{\partial L}{\partial w_1} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial w_1} = (\hat{y} - y) \cdot x_1 = (-2) \cdot 2 = -4$$
$$\frac{\partial L}{\partial w_2} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial w_2} = (\hat{y} - y) \cdot x_2 = (-2) \cdot 3 = -6$$

梯度向量如下：

$$\nabla L = [-2, -4, -6]$$

参数更新过程如下：

$$w_{0(new)} = w_{0(old)} - \alpha \cdot \frac{\partial L}{\partial w_0} = 0 - 0.05 \cdot (-2) = 0.1$$
$$w_{1(new)} = w_{1(old)} - \alpha \cdot \frac{\partial L}{\partial w_1} = 1 - 0.05 \cdot (-4) = 1.2$$
$$w_{2(new)} = w_{2(old)} - \alpha \cdot \frac{\partial L}{\partial w_2} = -1 - 0.05 \cdot (-6) = -0.7$$

新的参数如下：

$$w_0 = 0.1, \quad w_1 = 1.2, \quad w_2 = -0.7$$

3. 正则化

题 2 的基础上，若损失函数增加了 $L2$ 正则化项，正则化系数 $\lambda = 0.1$，那么损失函数值为多少，梯度向量又是多少？

$L2$ 正则化损失如下：

$$L = L(W) + \frac{\lambda}{2}(w_1^2 + w_2^2) = 2 + 0.1 = 2.1$$

梯度计算如下：

$$\frac{\partial L}{\partial w_0} = -2$$
$$\frac{\partial L}{\partial w_1} = -4 + \lambda w_1 = -4 + 0.1 \times 1 = -3.9$$
$$\frac{\partial L}{\partial w_2} = -6 + \lambda w_2 = -6 + 0.1 \times (-1) = -6.1$$

梯度向量如下：

$$\nabla L = [-2, -3.9, -6.1]$$

参数更新过程如下：

$$w_{0(new)} = w_{0(old)} - \alpha \cdot \frac{\partial L}{\partial w_0} = 0 - 0.05 \cdot (-2) = 0.1$$
$$w_{1(new)} = w_{1(old)} - \alpha \cdot \frac{\partial L}{\partial w_1} = 1 - 0.05 \cdot (-3.9) = 1.195$$
$$w_{2(new)} = w_{2(old)} - \alpha \cdot \frac{\partial L}{\partial w_2} = -1 - 0.05 \cdot (-6.1) = -0.695$$

新的参数如下：

$$w_0 = 0.1, \quad w_1 = 1.195, \quad w_2 = -0.695$$

四、反向传播计算题

1. 单层神经元

输入 $x = [1, 2]$，权重 $W = [0.5, -0.5]$，激活函数为 $sigmoid$，输出 y，目标值为 $y = 1$。损失为 MSE。

请计算损失 L，并求 $\frac{\partial L}{\partial W}$

线性部分输出如下：

$$z = W_1 x_1 + W_2 x_2 = 0.5 \cdot 1 + (-0.5) \cdot 2 = -0.5$$

激活输出如下：

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{0.5}}$$

损失 L 输出如下：

$$L = \frac{1}{2}\ (\hat{y} - y)^2 = \frac{1}{2}\ (\frac{1}{1 + e^{0.5}} - 1)^2 = \frac{e}{2(1 + e^{0.5})^2}$$

梯度计算如下：

$$\frac{\partial L}{\partial w_1} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial w_1} = (\hat{y} - y) \cdot \frac{e^{-z}}{(1+e^{-z})^2} \cdot x_1 = -\frac{e^{0.5}}{1+e^{0.5}} \cdot \frac{e^{0.5}}{(1+e^{0.5})^2} \cdot 1 = -\frac{e}{(1+e^{0.5})^3}$$

$$\frac{\partial L}{\partial w_2} = \frac{\partial L}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z} \cdot \frac{\partial z}{\partial w_2} = (\hat{y} - y) \cdot \frac{e^{-z}}{(1+e^{-z})^2} \cdot x_2 = -\frac{e^{0.5}}{1+e^{0.5}} \cdot \frac{e^{0.5}}{(1+e^{0.5})^2} \cdot 2 = -\frac{2e}{(1+e^{0.5})^3}$$

梯度向量如下：

$$\frac{\partial L}{\partial W} = \nabla L = [-\frac{e}{(1+e^{0.5})^3}, -\frac{2e}{(1+e^{0.5})^3}]$$

一、矩阵乘法+ $ReLU$ 激活+ 反向传播计算题

已知输入矩阵：

$$X = \begin{bmatrix} 1 & 0 & -1 \\ 2 & -1 & 3 \\ 0 & 1 & 2 \end{bmatrix}$$

参数矩阵与偏置：

$$W = \begin{bmatrix} 2 & -1 & 0 \\ 1 & 3 & -2 \end{bmatrix}$$

前向传播步骤：

$$Z = W\,X, \qquad A = RELU(Z)$$

其中 $RELU$ 激活函数为：

$$RELU(z) = max(0, z)$$

问题1：前向计算

1. 计算线性变换输出矩阵 Z

$$Z = W\,X = \begin{bmatrix} 2 & -1 & 0 \\ 1 & 3 & -2 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & -1 \\ 2 & -1 & 3 \\ 0 & 1 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 1 & -5 \\ 7 & -5 & 4 \end{bmatrix}$$

2. 计算激活输出矩阵 A

$$A = RELU(Z) = \begin{bmatrix} 0 & 1 & 0 \\ 7 & 0 & 4 \end{bmatrix}$$

问题2：反向传播计算

(1) 利用 $RELU$ 的导数（在 $z > 0$ 时为 1，在 $z \leq 0$ 时为 0）计算 $\frac{\partial L}{\partial Z}$

$$\frac{\partial L}{\partial Z} = \frac{\partial L}{\partial A} \odot \frac{\partial A}{\partial Z} = \begin{bmatrix} 1 & 0 & -2 \\ -1 & 2 & 1 \end{bmatrix} \odot \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix}$$

(2) 推导并计算 $\frac{\partial L}{\partial W} = \frac{\partial L}{\partial Z}\,X^\top, \qquad \frac{\partial L}{\partial X} = W^\top\,\frac{\partial L}{\partial Z}$

$$\frac{\partial L}{\partial W} = \frac{\partial L}{\partial Z}\,X^\top = \begin{bmatrix} 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 & 2 & 0 \\ 0 & -1 & 1 \\ -1 & 3 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ -2 & 1 & 2 \end{bmatrix}$$

$$\frac{\partial L}{\partial X} = W^\top\,\frac{\partial L}{\partial Z} = \begin{bmatrix} 2 & 1 \\ -1 & 3 \\ 0 & -2 \end{bmatrix} \cdot \begin{bmatrix} 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix} = \begin{bmatrix} -1 & 0 & 1 \\ -3 & 0 & 3 \\ 2 & 0 & -2 \end{bmatrix}$$

问题3：梯度下降更新

沿用第 2 题得到的梯度，设学习率 $\eta = 0.1$，使用标准梯度下降更新第 1 题中的参数：

$$W^{(new)} = W^{(old)} - \eta\,\frac{\partial L}{\partial W}$$

(1) 计算 $W^{(new)}$ 的数值结果

$$W^{(new)} = W^{(old)} - \eta\,\frac{\partial L}{\partial W} = \begin{bmatrix} 2 & -1 & 0 \\ 1 & 3 & -2 \end{bmatrix} - \begin{bmatrix} 0 & 0 & 0 \\ -0.2 & 0.1 & 0.2 \end{bmatrix} = \begin{bmatrix} 2 & -1 & 0 \\ 1.2 & 2.9 & -2.2 \end{bmatrix}$$

二、卷积神经网络前向传播计算题

网络结构如下：

- 输入图像：4×4 RGB 图像（3 通道）
- 卷积层：一个 $2 \times 2 \times 3$ 卷积核，步长为 2，补全为 1，激活函数为 $ReLU$
- 池化层：2×2 最大池化，步长为 2

- 全连接层：展平后连接 3 个神经元，使用 $softmax$ 输出
- 损失函数为交叉熵损失 + $L1$ 正则化（不含偏置）

图像输入如下：

$$\mathbf{R}\ \textbf{通道}:\begin{bmatrix}1&2&0&1\\0&1&2&0\\1&0&1&2\\2&1&0&1\end{bmatrix}\quad \mathbf{G}\ \textbf{通道}:\begin{bmatrix}0&1&0&1\\2&1&1&0\\1&2&0&1\\1&1&2&0\end{bmatrix}\quad \mathbf{B}\ \textbf{通道}:\begin{bmatrix}1&0&2&1\\1&0&1&1\\2&1&0&2\\0&1&1&0\end{bmatrix}$$

卷积核：

$$W^{(R)}=\begin{bmatrix}1&0\\-1&1\end{bmatrix},\quad W^{(G)}=\begin{bmatrix}0&1\\1&-1\end{bmatrix},\quad W^{(B)}=\begin{bmatrix}1&-1\\0&1\end{bmatrix}$$

全连接层参数：

$$W_{fc}=\begin{bmatrix}1&0&-1&1\\0&1&1&-1\\1&-1&0&0\end{bmatrix},\quad b_{fc}=\begin{bmatrix}0\\1\\-1\end{bmatrix}$$

真实标签：

$$y=\begin{bmatrix}1\\0\\0\end{bmatrix}$$

即正确类别为第一个

正则化系数：$\lambda=0.01$

要求：

(1) 卷积层前向传播：

对图像进行三通道卷积，三通道分别进行卷积操作后相加，再应用 $ReLU$，写出输出特征图

分别对 R/G/B 三个通道做 2×2 卷积（stride=2,pad=1），得到三个 3×3 特征图，再相加：

$$Y_R=\begin{bmatrix}1&-2&-1\\1&2&-2\\0&1&1\end{bmatrix},\quad Y_G=\begin{bmatrix}0&1&1\\1&3&1\\1&2&0\end{bmatrix},\quad Y_B=\begin{bmatrix}1&2&0\\1&-1&1\\0&0&0\end{bmatrix}$$

三通道相加：

$$Y=Y_R\ +\ Y_G\ +\ Y_B=\begin{bmatrix}2&1&0\\3&4&0\\1&3&1\end{bmatrix}$$

$ReLU$ 激活：

$$A_{conv}=ReLU(A)=\begin{bmatrix}2&1&0\\3&4&0\\1&3&1\end{bmatrix}$$

(2) 池化层前向传播：

对特征图进行 2×2 最大池化，步长为 1，写出池化层输出

池化层输出为：

$$A_{pool}=\begin{bmatrix}4&4\\4&4\end{bmatrix}$$

(3) 输出层与损失计算：

将池化层输出展平成向量 $x=[a1,a2,a3,a4]^T$，计算输出层线性变换 $z=W_{fc}\cdot x+b_{fc}$

池化层输出展平为：

$$x=[4\quad 4\quad 4\quad 4]^T$$

全连接层输出为

$$z = W_{fc} \cdot x + b_{fc} = \begin{bmatrix} 1 & 0 & -1 & 1 \\ 0 & 1 & 1 & -1 \\ 1 & -1 & 0 & 0 \end{bmatrix} \cdot [4 \quad 4 \quad 4 \quad 4]^T + \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 4 \\ 4 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 4 \\ 5 \\ -1 \end{bmatrix}$$

使用 $softmax$ 计算 $\hat{y} = \frac{e^{s_i}}{\sum_{j=1}^{3} e^{s_j}} \quad (i = 1, 2, 3)$

最终经过激活函数 $softmax$ 输出为：

$$\hat{y} = \frac{e^{z_i}}{e^4 + e^5 + e^{-1}} = \begin{bmatrix} \frac{e^4}{e^4+e^5+e^{-1}} \\ \frac{e^5}{e^4+e^5+e^{-1}} \\ \frac{e^{-1}}{e^4+e^5+e^{-1}} \end{bmatrix}$$

计算交叉熵损失 $L_{ce} = -\sum_{i=1}^{3} y_i log(\hat{y}_i)$

交叉熵损失如下：

$$L_{ce} = -\sum_{i=1}^{3} y_i log(\hat{y}_i) = -[1 \cdot log(\frac{e^4}{e^4 + e^5 + e^{-1}}) + 0 \cdot log(\frac{e^5}{e^4 + e^5 + e^{-1}}) + 0 \cdot log(\frac{e^{-1}}{e^4 + e^5 + e^{-1}})] = -log(\frac{e^4}{e^4 + e^5 + e^{-1}})$$

计算 $L1$ 正则化项（对 $W^{(R)}$，$W^{(G)}$，$W^{(B)}$，W_{fc}） $L_{reg} = \lambda \sum_{i,j} |W_{fc_{i,j}}|$

$$\|W^{(R)}\|_1 = 3, \quad \|W^{(G)}\|_1 = 3, \quad \|W^{(B)}\|_1 = 3, \quad \|W_{(fc)}\|_1 = 8$$

$$L_{reg} = 0.01 \times (3 + 3 + 3 + 8) = 0.17$$

写出总损失 $L = L_{ce} + L_{reg}$

$$L = -log(\frac{e^4}{e^4 + e^5 + e^{-1}}) + 0.17$$

三、Layer Normalization 计算题（两行样本，含公式）

某层的输出为：

$$X = \begin{bmatrix} 2 & 4 & 6 & 8 \\ 1 & 3 & 5 & 7 \end{bmatrix}$$

其中每一行代表一个样本，特征维度为 4。

Layer Normalization 对每一个样本（每一行）进行标准化，其计算步骤如下：

$$\mu_i = \frac{1}{d} \sum_{j=1}^{d} X_{i,j}, \quad \sigma_i^2 = \frac{1}{d} \sum_{j=1}^{d} (X_{i,j} - \mu_i)^2$$

标准化：

$$\hat{X}_{i,j} = \frac{X_{i,j} - \mu_i}{\sqrt{\sigma_i^2}}$$

缩放和平移（本题中为恒等映射）：

$$Y = \gamma \odot \hat{X} + \beta, \quad \gamma = [1 \quad 1 \quad 1 \quad 1], \quad \beta = [0 \quad 0 \quad 0 \quad 0]$$

请计算：

(1) 两个样本的均值 μ_1, μ_2

$$\mu_1 = \frac{2 + 4 + 6 + 8}{4} = 5$$
$$\mu_2 = \frac{1 + 3 + 5 + 7}{4} = 4$$

(2) 两个样本的方差 σ_1^2, σ_2^2

$$\sigma_1^2 = \frac{(2-5)^2 + (4-5)^2 + (6-5)^2 + (8-5)^2}{4} = 5$$
$$\sigma_2^2 = \frac{(1-4)^2 + (3-4)^2 + (5-4)^2 + (7-4)^2}{4} = 5$$

(3) 标准化结果矩阵 $\hat{X}$

$$\hat{X} = \begin{bmatrix} -\frac{3}{\sqrt{5}} & -\frac{1}{\sqrt{5}} & \frac{1}{\sqrt{5}} & \frac{3}{\sqrt{5}} \\ -\frac{3}{\sqrt{5}} & -\frac{1}{\sqrt{5}} & \frac{1}{\sqrt{5}} & \frac{3}{\sqrt{5}} \end{bmatrix}$$

(4) LayerNorm 的最终输出矩阵 Y

$$Y = \gamma \odot \hat{X} + \beta = \begin{bmatrix} 1 & 1 & 1 & 1 \end{bmatrix} \odot \begin{bmatrix} -\frac{3}{\sqrt{5}} & -\frac{1}{\sqrt{5}} & \frac{1}{\sqrt{5}} & \frac{3}{\sqrt{5}} \\ -\frac{3}{\sqrt{5}} & -\frac{1}{\sqrt{5}} & \frac{1}{\sqrt{5}} & \frac{3}{\sqrt{5}} \end{bmatrix} + \begin{bmatrix} 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} -\frac{3}{\sqrt{5}} & -\frac{1}{\sqrt{5}} & \frac{1}{\sqrt{5}} & \frac{3}{\sqrt{5}} \\ -\frac{3}{\sqrt{5}} & -\frac{1}{\sqrt{5}} & \frac{1}{\sqrt{5}} & \frac{3}{\sqrt{5}} \end{bmatrix}$$

四、$Dropout$ 计算题（$VanillaDropout$）

已知某一层的输出矩阵为：

$$H = \begin{bmatrix} 4 & -2 & 0 & 6 \\ 1 & 3 & -4 & 2 \end{bmatrix}$$

$Dropout$ 保留率为：

$$p = 0.5$$

说明：$Dropout$ 的含义是对每个神经元独立地以概率 p 进行保留，以概率 $1-p$ 将其置为 0。因此，每次得到的 $mask$ 是随机的，并不保证恰好一半神经元被保留。

假设某次训练中生成的 $Dropoutmask$ 为：

$$mask = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 1 \end{bmatrix}$$

在 $VanillaDropout$ 中：

- 训练阶段：直接将被丢弃的神经元置零，不进行缩放

$$H_{train} = H \odot mask$$

- 测试阶段：不再丢弃神经元，为使输出强度与训练期望一致，需要将激活整体乘以保留率

$$H_{test} = p \cdot H$$

问题：

计算训练阶段输出 H_{train}

$$H_{train} = H \odot mask = \begin{bmatrix} 4 & -2 & 0 & 6 \\ 1 & 3 & -4 & 2 \end{bmatrix} \odot \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 4 & 0 & 0 & 0 \\ 0 & 3 & -4 & 2 \end{bmatrix}$$

计算测试阶段输出 H_{test}

$$H_{test} = p \cdot H = 0.5 \cdot \begin{bmatrix} 4 & -2 & 0 & 6 \\ 1 & 3 & -4 & 2 \end{bmatrix} = \begin{bmatrix} 2 & -1 & 0 & 3 \\ 0.5 & 1.5 & -2 & 1 \end{bmatrix}$$

简要解释测试阶段为什么要乘以p（一句话即可）

保证测试阶段的输出强度与训练期望一致。